PROBABILIDAD Y ESTADISTICA

Semester 1 - 2025

Jaime Nazar Anchorena
Ingenieria Informatica

Contents

1 Estadistica descriptiva **3**
1.1 Representacion grafica 3
1.1.1 Histograma 3
1.1.2 Poligono de frecuencias 3
1.2 Medidas de resumen 4
1.2.1 Datos sin agrupar 4
1.2.2 Datos agrupados 7
1.2.3 Boxplot 8
1.2.4 Outliers 8

1 Estadistica descriptiva

Es muy complicado sensar a toda la poblacion, entonces se procede a tomar muestras representativas. Estas muestras se toman al azar(suficiente para nosotros).

Los datos tomados se representan en el siguiente conjunto:

$$\{x_i\}_{i=1}^{n}$$

Donde n es el tamano de la muestra, siendo N el de la poblacion($< \infty$). Estos datos pueden ser cualitativos(fenero, color de ojos, etc.) o cuantitativos(numero o vectore).

Definition 1.1. Experimento Aleatorio

1. Es posible repetir el experimento indefinidamente sin cambiar las condiciones.
2. El conjunto de todos los resultados posibles se conoce como el **espacio muestral** del experimento, pero no se puede identificar un resultado en particular.
3. Los resultados parecen aleatoreos a medida que se repite el experimento, pero al repetir un gran numero de veces comienza a aparecer un patron de regularidad. A partir del patron se puede construir un modelo matematico con el cual analizar el experimento.

1.1 Representacion grafica

Primero se los representa en un grafico de forma ordenada, luego se los puede separar en pedazon mas chicos llamados **bines**, los cuales son siempre abiertos a izquierda y cerrados a derecha: (}.

Definition 1.2. Frecuencia

- **Frecuencia absoluta**: Numero de ocurrenciar dentro de cada bin/grupo.
- **Frecuencia relativa**: Representa un grupo en relacion al total, de manera que si son 3 de 200, entonces la frecuencia relativa sera $\frac{3}{200}$.
- **Frecuencia absoluta acumulada**: Las frecuencias absolutas sumadas de izquierda a derecha, es decir, si el grupo 1 tiene 3 y el grupo 2 tiene 5, entonces la frecuencia acumulada del grupo 2 sera 8.
- **Frecuencia relativa acumulada**: Igual a la frecuencia absoluta acumulada, lo que se va acumulando son las frecuencias relativas, por lo tanto el ultimo grupo tiene que tener 1.

1.1.1 Histograma

Util para visualizar la informacion.

1.1.2 Poligono de frecuencias

Usando el histograna, se trazan lineas entre cada barra.

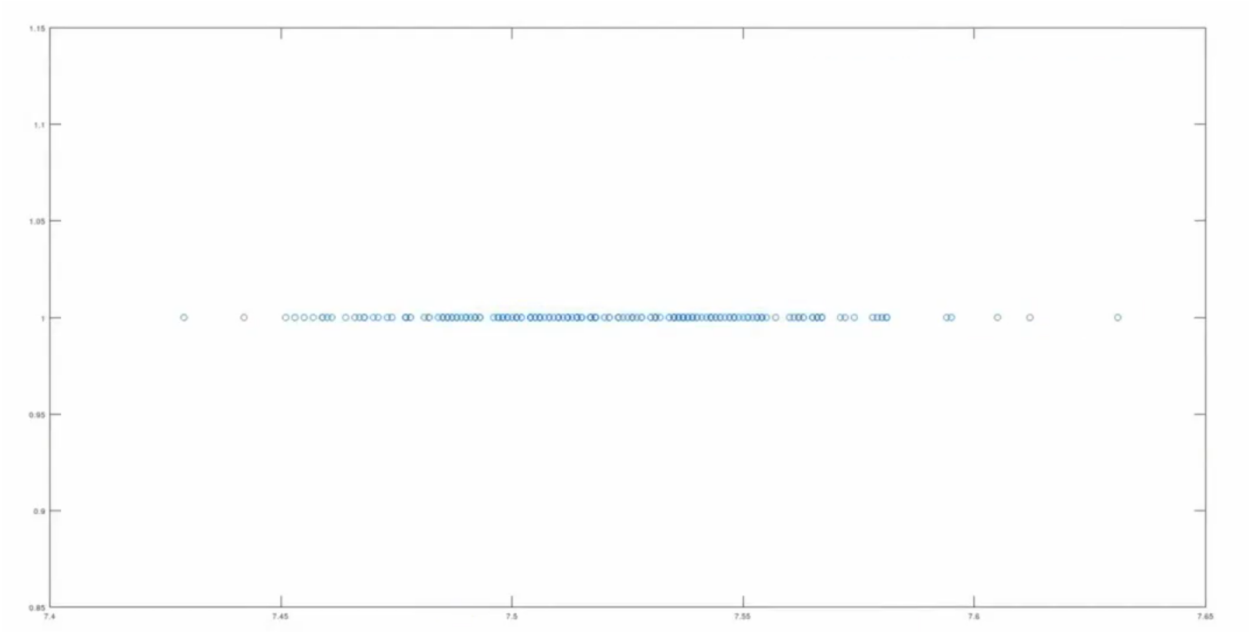

Figure 1: Datos representados de manera ordenada

1.2 Medidas de resumen

1.2.1 Datos sin agrupar

Definition 1.3. Media arismetica(o promedio), busca representar el "centro" de los datos de una variable cuantitativa. Sean $x_1, ..., x_n$ datos:

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Notas que los datos conocidos se escriben con minuscula por convencion.

Definition 1.4. Desvio estandard o varianza muestral, una medida de dispersion de los datos ya que la **media arismetica** puede no ser lo que parece(diferente tamano de muestra, dispersion, etc.). Esta basada en la diferencia de los datos con la media

$$S^2 = \frac{1}{n-1} \cdot \sum_{i=1}^{n} (x_i - \bar{x})^2$$

Elevado al cuadrado pued puede dar negativo y no queremos eso, no se utiliza el modulo porque no es derivable. El desvio estandard es el valor de S.

Property 1.5. $S = 0 \Leftrightarrow$ *Los datos son constantes(opuesto a variables).*

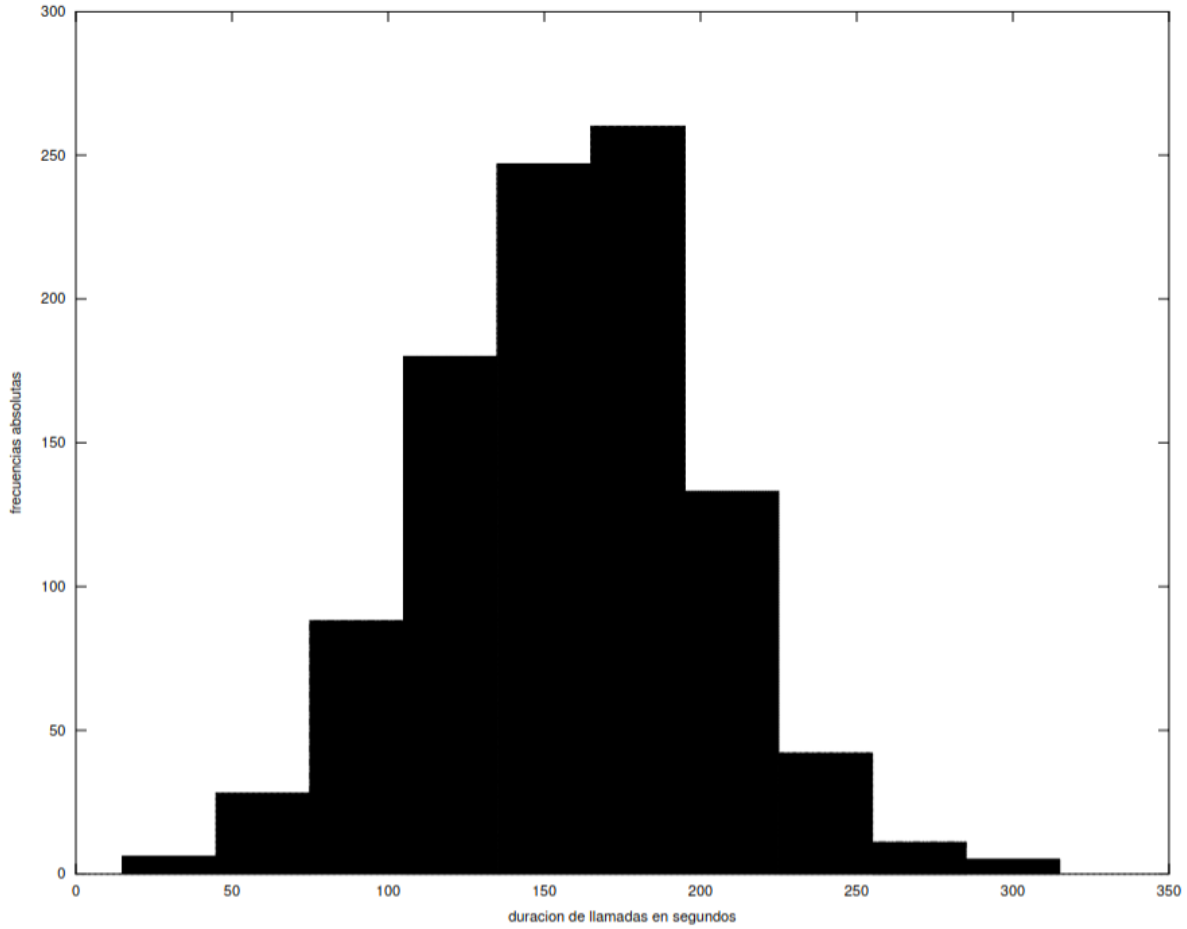

Figure 2: Histograma de frecuencias absolutas

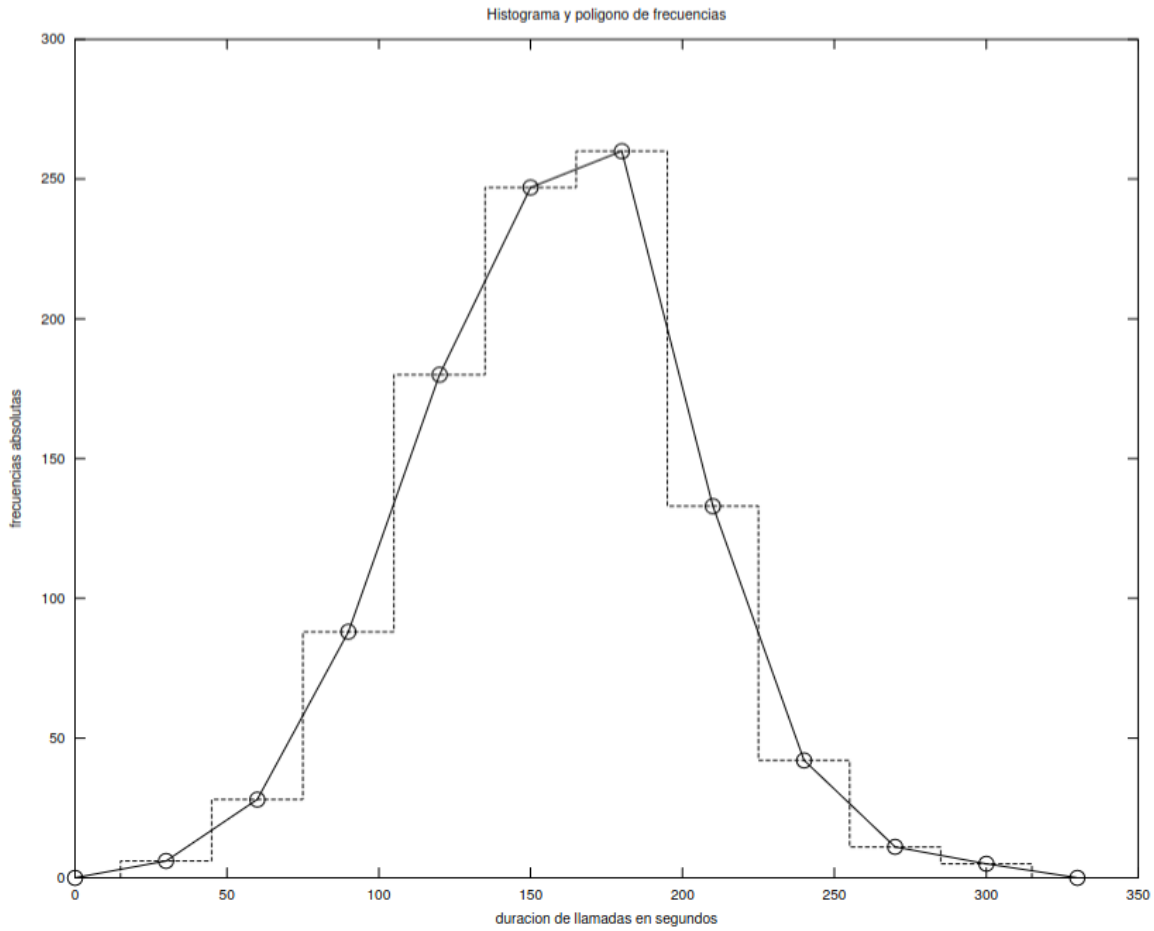

Figure 3: Poligono de frecuencias y histograma

Definition 1.6. Coeficiente de simetria, mide el equilibrio entro los valores por debajo de la media y por arriba de la media.

$$g = \frac{1}{n \cdot S^3} \cdot \sum_{i=1}^{n} (x_i - \bar{x})^3$$

- $g > 0 \rightarrow$ La variable es asimetrica derecha.
- $g \approx 0 \rightarrow$ La variable es relativamente simetrica.
- $g < 0 \rightarrow$ La variable es asimetrica izquierda.

Definition 1.7. Kurtosis, puede diferencias las distribuciones cuando todas las anteriores coinciden. Hace referencia a que pesos tienen los datos mas alejados de la media.

$$k = \frac{1}{n \cdot S^4} \cdot \sum_{i=1}^{n} (x_i - \bar{x})^4$$

El 3 es para poder interpretar la Kurtosis usando la distribucion normal como referencia.s

- $k > 0 \rightarrow$ El peso de las colas es menor al de una distribucion normal.
- $k \approx 0 \rightarrow$ El peso de las colas es similar a la de una distribucino normal.
- $k < 0 \rightarrow$ El peso de las colas es mayor al de una distribucion normal.

Definition 1.8. Mediana, media de tendencia central. Deja por lo menos 5% de ;ps datos a la izquierda y el otro 50% de los datos a la derecha(aunque no siempre se consigue). Cuando tengo un numero par de datos y no hay valor intermedio se conoce como un **caso de paridad**, hay varias maneras de obtener dicho valor(R presenta 4 opciones), pero la mas simple es sacar el promedio.

Definition 1.9. Cuartiles, dividen los datos en 4, ante paridad se procede igual que la mediana(q2).

- **Primer cuartil(q_1)**: Deja el 25% de los datos a su izquierda.
- **Segundo cuartil(mediana o q_2)**: Deja el 50% de los datos a su izquierda.
- **Tercer cuartil(q_3)**: Deja el 75% de los datos a su izquierda.

1.2.2 Datos agrupados

A veces los datos vienen en rangos de valores, de L_i(limite inferior) a L_s(limite superior). Se cuenta cuantos datos se observan en cada rango. La cantidad de datos en cada rango es la frecuencia absoluta(f_i). No dan siempre lo mismo que con los datos reales, pero se aproxima.

Definition 1.10. Media arismetica(o promedio), similar a datos sin agrupar:

$$\bar{x}_{ag} = \frac{\sum_{i=1}^{n} x_i \cdot f_i}{n}$$

Definition 1.11. Desvio estandard o varianza muestral, similar a datos sin agrupar

$$S_{ag}^2 = \frac{1}{n-1} \cdot \sum_{i=1}^{n} (x_i - \bar{x})^2 \cdot f_i$$

Definition 1.12. Mediana, la logica es distinta, entonces se foccaliza en cuandtos datos fueron acumulados hasta cada limite superior. Se utiliza la frecuencia acumulada(F_i). Luego, elijo el intervalo que acumula el 50% de los datos, entonces saco la mediana mediante interpolacion lineal.

Definition 1.13. Cuartiles, caso similar a la mediana, en caso de no tener un conjunto que acumule la cantidad exata se procede de la siguiente manera(recordar que la mediana tambien es q_2).

$$q_{1_{ag}} = L_{i_i} + \frac{0.25 \cdot n - F_{i-1}}{f_i} \cdot (L_{s_i} - L_{i_i})$$

Donde i es el intervalo en el que se encuentra el cuartil. Estamos asumiendo que se distribuyen de forma equitativa(AKA interpolacion lineal).

1.2.3 Boxplot

Combina las medidas de resumen para representar como se distribuyen los datos.

- **Alto**: La "distancia" entre q_1 y q_3 o **IQR**.
- **Linea horizontal**: Representa la mediana.
- **Lineas verticales**: Representa el minimos y el maximo de los datos.

Se puede usar para detectar errores pues es facil ver valores fuera de lugar.

1.2.4 Outliers

Valores considerados atipicos, usualmente indican un error en algun dato, por eso es util poder detectarlos. Se consideran atipicos debido a que se consideran lo suficientemente alejados del 50% central. Limites de lo que se considera normal segun Tukey:

- $L_w = q_1 - 1.5 \cdot (q_3 - q_1) = q_1 - 1.5 \cdot IQR$
- $U_w = q_3 - 1.5 \cdot (q_3 - q_1) = q_3 - 1.5 \cdot IQR$

	Datos sin agrupar (n datos)		Datos agrupados (n datos, L intervalos)
Media:	$\overline{x} = \frac{\sum_{i=1}^{n} x_i}{n}$	$\Rightarrow$	$\overline{x}_{Ag} = \frac{\sum_{i=1}^{L} x_i \cdot f_i}{n}$
Desvío:	$s = \sqrt{\frac{\sum_{i=1}^{n} (x_i - \overline{x})^2}{n-1}}$	$\Rightarrow$	$s_{Ag} = \sqrt{\frac{\sum_{i=1}^{L} (x_i - \overline{x}_{Ag})^2 \cdot f_i}{n-1}}$
Simetría:	$\gamma = \frac{\sum_{i=1}^{n} (x_i - \overline{x})^3}{n \cdot s^3}$	$\Rightarrow$	$\gamma_{Ag} = \frac{\sum_{i=1}^{L} (x_i - \overline{x}_{Ag})^3 \cdot f_i}{n \cdot s_{Ag}^3}$
Kurtosis:	$\kappa = \frac{\sum_{i=1}^{n} (x_i - \overline{x})^4}{n \cdot s^4} - 3$	$\Rightarrow$	$\kappa_{Ag} = \frac{\sum_{i=1}^{L} (x_i - \overline{x}_{Ag})^4 \cdot f_i}{n \cdot s_{Ag}^4} - 3$

Figure 4: Resumen de ecuaciones

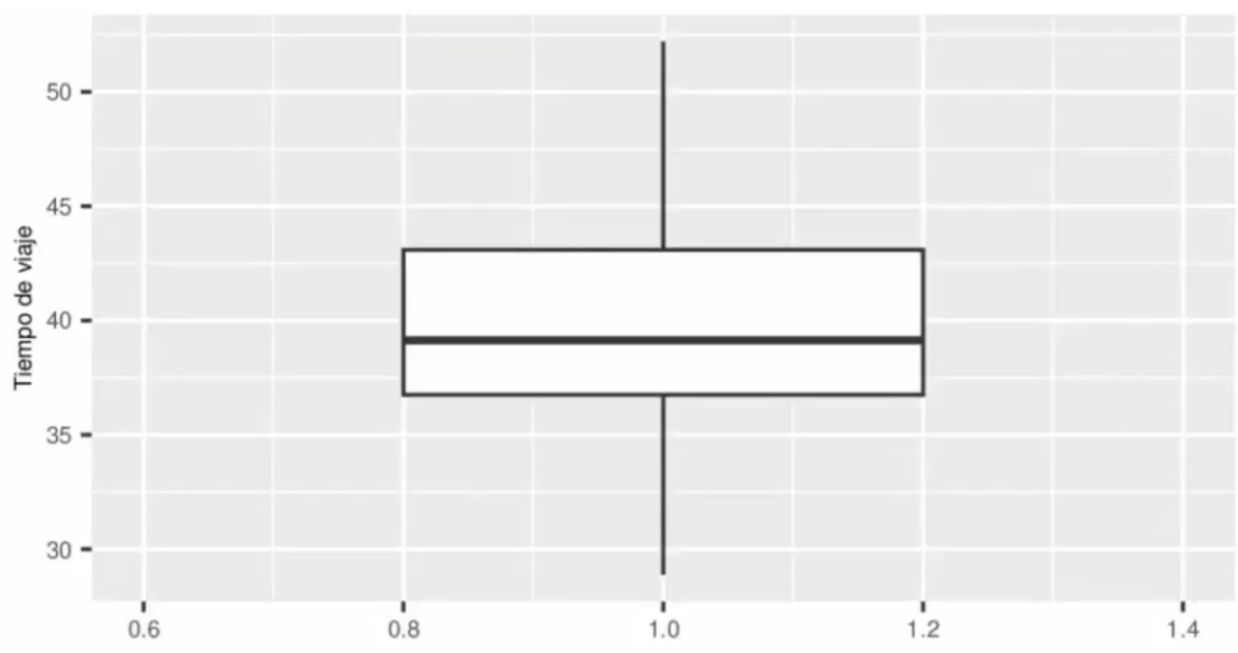

Figure 5: Boxplot