Procesos Estocásticos

Pablo I. Fierens
Basado en notas de clase de Francisco Villaverde

7 de agosto de 2024

Índice general

1. Introducción a los procesos estocásticos **5**
1.1. ¿Qué es un proceso estocástico? . . . 5
1.2. Algo de notación . . . 6
1.3. Caminata aleatoria . . . 6
1.3.1. Probabilidades marginales . . . 7
1.3.2. Una distribución conjunta . . . 8
1.3.3. Autocorrelación . . . 8
1.3.4. Generación con computadora . . . 9
1.4. Caracterización de un proceso estocástico . . . 10
1.4.1. Procesos de Markov . . . 10
1.4.2. Procesos estacionarios y ergódicos . . . 11
1.4.3. Incrementos estacionarios e independientes . . . 12
1.5. Referencias . . . 13

2. Procesos de conteo **15**
2.1. ¿Qué se cuenta? . . . 15
2.2. Proceso de Bernoulli . . . 15
2.2.1. Distribución marginal . . . 16
2.2.2. Tiempos entre eventos . . . 18
2.2.3. Un ejemplo errado . . . 19
2.3. Proceso de Poisson . . . 20
2.3.1. Distribución marginal . . . 21
2.3.2. Tiempos entre eventos . . . 23
2.3.3. Relación entre los procesos de Bernoulli y de Poisson . . . 25
2.3.4. Un ejemplo infantil . . . 25
2.4. Generación con computadora . . . 26
2.5. Referencias . . . 27

3. Cadenas de Markov **29**
3.1. Cadenas de Markov de tiempo discreto . . . 30
3.2. Generación con computadora . . . 31
3.3. Algunos ejemplos . . . 32
3.3.1. El vendedor viajero . . . 32
3.3.2. El bebé . . . 33
3.3.3. La vida . . . 34
3.3.4. La vida más compleja . . . 34
3.3.5. Juego de pelota . . . 34
3.4. Clasificación de los estados . . . 36
3.5. Distribución a largo plazo . . . 38
3.5.1. Cálculo de la distribución estacionaria . . . 41
3.6. Cadenas de Markov absorbentes . . . 42
3.7. Referencias . . . 43

Capítulo 1

Introducción a los procesos estocásticos

1.1. ¿Qué es un proceso estocástico?

Una forma de entender qué es un proceso estocástico es mediante algunos ejemplos:

- Juan mide la temperatura su corporal en la axila izquierda. Al valor medido en el instante t lo llamamos $Q(t)$.
- Rosa atiende en un bar. El número de personas que se acercaron a la barra desde el inicio del día hasta el instante t lo llamamos $N(t)$.
- En una fábrica de alambres, se toma un rollo al azar. Definimos $D(x)$ como la densidad lineal de masa del alambre a una distancia x de uno de los extremos.
- El valor de una acción en el inicio de la rueda de la bola del día n puede escribirse como $A(n)$.

Escrito de esta forma, parecen ser sólo ejemplos de funciones determinísticas de una variable. Sin embargo:

- La temperatura corporal depende de una gran cantidad de variables que, tal vez, no puedan ser cuantificadas. Además, las mediciones son inexactas y pueden contener errores.
- La cantidad de personas que debe atender Rosa depende de muchos factores y es difícil (o imposible) describirla exactamente.
- Al fabricar el alambre y enrollarlo, puede haber peque?as diferencias que llevan a que la densidad sea homogénea. Esas diferencias son difíciles de predecir, dependiendo de muchas condiciones de las máquinas y personas involucradas en el proceso.
- Si fuese simple predecir el valor de una acción, yo no estaría escribiendo estas líneas y usted no las estaría leyendo...

Es decir, en todos los casos, hay una incerteza en el valor de la "función" en cada punto. Si esa incerteza es cuantificable, entonces $Q(t)$, $N(t)$, $D(x)$ e $A(n)$ **son variables aleatorias para cada valor de t, x o n**. Dicho de otro modo, en cada caso tenemos un conjunto de **variables aleatorias indexadas por un parámetro**, continuo como en los casos de la temperatura, el número de clientes en el bar o la densidad, o discreto como en el caso de la acción. Más aún, es de esperar que esas variables aleatorias estén relacionadas. Por ejemplo, uno esperaría que la temperatura corporal a las 13:01 hs. no sea muy distinta a la de aquella a las 13:00 hs.: claramente debe haber una relación cuantificable entre $Q(t+1)$ y $Q(t)$, con $t = 13$ hs. En conclusión, tenemos la siguiente

Definición 1.1.1 (Proceso estocástico). Una colección de variables aleatorias $\{X(t)\}_{t\in\mathbb{T}}$ se denomina un *proceso estocástico* indexado por $t \in \mathbb{T}$, donde $\mathbb{T}$ es el *espacio de parámetro*. El conjunto de valores posibles de $X(t)$, $\mathbb{E}$, se denomina el *espacio de estados*.

Veamos cuál es el espacio de parámetro y el espacio de estados en los ejemplos:

- $Q(t)$: La temperatura corporal ciertamente es un valor real. Podríamos limitarla a cierto rango (por supuesto, no va a ser inferior a -274 grados Celsius), pero hagámoslo simple: $\mathbb{E} = \mathbb{R}$. En cuanto al espacio de parámetros, el tiempo es un continuo. Suponiendo que comenzamos a medir en $t = 0$, entonces $\mathbb{T} = \mathbb{R}^{\geq 0}$.
- Rosa no puede contar clientes negativos ni fraccionarios, por lo que $\mathbb{E} = \mathbb{N}^0$ (debemos incluir el 0). Por otro lado, el tiempo es nuevamente continuo: $\mathbb{T} = \mathbb{R}^{\geq 0}$.
- Dado que no puede existir una densidad negativa, $\mathbb{E} = \mathbb{R}^{\geq 0}$. Si el largo del cable es L, entonces $\mathbb{T} = [0, L]$.
- El valor de una acción no puede (??) ser negativo. Podríamos modelarlo como un continuo de valores: $\mathbb{E} = \mathbb{R}^{\geq 0}$. En cuanto al tiempo, en este caso es discreto: $\mathbb{T} = \mathbb{N}^0$.

Como vemos, tanto el espacio de parámetros como el espacio de estados puede ser continuo o discreto.

¿Se puede construir un proceso estocástico de cualquier forma o hay que seguir algunas reglas? La verdad, es necesario tener algunos cuidados técnicos para que tenga sentido matemático la construcción. Sin embargo, eso está más allá del alcance de estas notas.

1.2. Algo de notación

Cuando trabajamos con variables aleatorias discretas, definimos la función de masa de probabilidad conjunta de dos variables aleatoria X e Y como

$$p_{X,Y}(x, y) = \mathrm{P}\left(X = x, Y = y\right). \tag{1.1}$$

Cuando se trabaja con procesos estocásticos, esta notación es un poco engorrosa. Por ejemplo,

$$\begin{aligned}&\mathrm{p}_{X(t_1),X(t_2),X(t_3),X(t_4),X(t_5)}(u, v, w, x, y) = \\ &\mathrm{P}\left(X(t_1) = u, X(t_2) = v, X(t_3) = w, X(t_4) = x, X(t_5) = y\right).\end{aligned} \tag{1.2}$$

En realidad, no existe una notación ideal y todo es un poco una cuestión de gustos. Pero, en ocasiones, utilizaremos la siguiente notación:

$$\begin{aligned}&\mathrm{p}(u, t_1; v, t_2; w, t_3; x, t_4; y, t_5) = \\ &\mathrm{P}\left(X(t_1) = u, X(t_2) = v, X(t_3) = w, X(t_4) = x, X(t_5) = y\right).\end{aligned} \tag{1.3}$$

Del mismo modo, en caso de un espacio de estados continuo, usaremos la siguiente notación para una densidad de probabilidades conjunta:

$$\begin{aligned}&\mathrm{f}(u, t_1; v, t_2; w, t_3; x, t_4; y, t_5) = \\ &\mathrm{f}\, X(t_1), X(t_2), X(t_3), X(t_4), X(t_5)(u, v, w, x, y).\end{aligned} \tag{1.4}$$

1.3. Caminata aleatoria

Existen varios conceptos relacionados con procesos estocásticos que debemos introducir. Sin embargo, es más simple entenderlos en contexto, esto es, usando un ejemplo concreto. Por ello, introducimos un ejemplo que, de hecho, es muy importante en sí mismo: la *caminata aleatoria*.

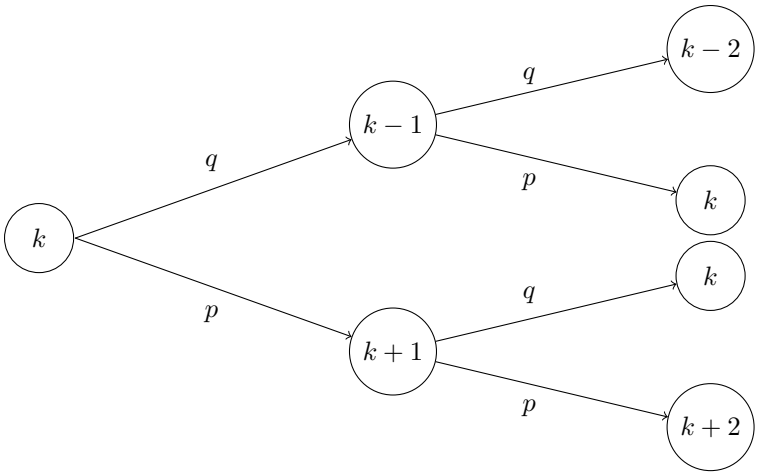

Figura 1.1: Estructura de árbol de la caminata aleatoria.

La caminata aleatoria en una dimensión está descripta por $X(n)$, esto es, la posición de una partícula (individuo, célula, conejo, extraterrestre, ...) en el instante n, $n \in \mathbb{N}^0$. La partícula se mueve de la siguiente forma:

- Inicialmente, se encuentra en la posición 0: $X(0) = 0$.
- En cada instante de tiempo, la partícula se mueve una unidad a la derecha con probabilidad p o una unidad a la izquierda con probabilidad $q = 1 - p$. Por lo tanto, podemos escribir

$$\mathrm{P}\big(X(n+1) = k|\, X(n) = m\big) = \begin{cases} p & k = m+1, \\ q & k = m-1, \\ 0 & |k-m| \neq 1. \end{cases} \tag{1.5}$$

Otra forma de representar la caminata aleatoria es mediante una *estructura de árbol*, como se presenta en la Fig. 1.3.

El espacio de parámetro es $\mathbb{T} = \mathbb{N}^0$. ?Y el espacio de estados? Si en el instante 0 la partícula se encuentra en 0, entonces $\mathcal{R}_{X(0)} = \{0\}$. De ahí, sólo puede saltar a izquierda o a derecha una unidad (?y no se puede quedar en el mismo lugar!), por lo que $\mathcal{R}_{X(1)} = \{-1, +1\}$. En tiempo $n = 1$, las transiciones posibles son: $-1 \to -2$, $-1 \to 0$, $+1 \to 0$, $+1 \to +2$. Por tanto, $\mathcal{R}_{X(2)} = \{-2, 0, +2\}$. En general, tenemos:

$$\mathcal{R}_{X(n)} = \{-n, -n+2, \cdots, n-2, n\}. \tag{1.6}$$

Finalmente, el espacio de estados es

$$\mathbb{E} = \bigcup_{n \in \mathbb{N}^0} \mathcal{R}_{X(n)} = \mathbb{Z}. \tag{1.7}$$

1.3.1. Probabilidades marginales

Llamemos $D(n)$ al número de pasos o saltos hacia la derecha hasta el instante de tiempo n (incluido). ?Qué tipo de variable aleatoria es $D(n)$? Los pasos son independientes entre sí y la probabilidad de dar un paso hacia derecha es siempre la misma. Por lo tanto, $D(n) \sim \text{Binomial}(n, p)$.

Podemos relacionar la posición $X(n)$ con $D(n)$. En efecto, $X(n)$ es igual al número de pasos a la derecha menos el número de pasos a la izquierda. Como el número de pasos a la izquierda es $n - D(n)$, tenemos

$$X(n) = D(n) - (n - D(n)) = 2D(n) - n. \tag{1.8}$$

Por lo tanto, para todo $k \in \mathcal{R}_{X(n)}$

$$\mathrm{p}(k,n) = \mathrm{P}\left(X(n)=k\right) = \mathrm{P}\left(2D(n)-n=k\right) = \mathrm{P}\left(D(n)=\frac{n+k}{2}\right) \tag{1.9}$$

$$= \binom{n}{\frac{n+k}{2}} p^{\frac{n+k}{2}} q^{\frac{n-k}{2}}. \tag{1.10}$$

1.3.2. Una distribución conjunta

Dada la Ec. (1.5), tenemos que

$$\mathrm{p}(x,n+1;y,n) = \mathrm{P}\left(X(n+1)=x, X(n)=y\right) = \mathrm{P}\big(X(n+1)=x|\, X(n)=y\big) \times \mathrm{P}\left(X(n)=y\right). \tag{1.11}$$

De un instante de tiempo a otro, se da un paso a izquierda o uno a derecha y, por tanto,

$$\mathrm{p}(x,n+1;y,n) = \begin{cases} \binom{n}{\frac{n+y}{2}} p^{\frac{n+y+2}{2}} q^{\frac{n-y}{2}} & x=y+1,\ y\in\mathcal{R}_{X(n)} \\ \binom{n}{\frac{n+y}{2}} p^{\frac{n+y}{2}} q^{\frac{n-y+2}{2}} & x=y-1,\ y\in\mathcal{R}_{X(n)} \\ 0 & \|x-y|\neq 1 \text{ o } y\notin\mathcal{R}_{X(n)} \end{cases} \tag{1.12}$$

donde hemos usado Ec. (1.10).

1.3.3. Autocorrelación

Una medida habitual en procesos estocásticos es la autocorrelación:

Definición 1.3.1 (Autocorrelación)**.** La autocorrelación de un proceso estocástico $X(t)$ está definida como

$$\mathrm{R}_{XX}(t_1,t_2) = \mathrm{E}\left[X(t_1)X(t_2)\right] \qquad \forall t_1,t_2\in\mathbb{T}. \tag{1.13}$$

Por su parte, la autocovarianza viene definida por

$$\mathrm{C}_{XX}(t_1,t_2) = \mathrm{E}\left[\left(X(t_1)-\mathrm{E}\left[X(t_1)\right]\right)\left(X(t_2)-\mathrm{E}\left[X(t_2)\right]\right)\right] \qquad \forall t_1,t_2\in\mathbb{T}. \tag{1.14}$$

Obsérvese que la autocorrelación no es equivalente al coeficiente de correlación de dos variables aleatorias. De todas formas, habla en cierta forma, de la *relación* lineal de los valores del proceso estocástico en dos instantes de tiempo distintos.

No trabajaremos mucho con la autocorrelación ya que va más allá de los alcances de estas notas. Sólo a modo ilustrativo, calcularemos la autocorrelación en en la caminata aleatoria para algunos casos sencillos:

$$\begin{aligned} \mathrm{R}_{XX}(n,n) &= \mathrm{E}\left[X(n)X(n)\right] = \mathrm{E}\left[(2D(n)-n)^2\right] = 4\mathrm{E}\left[D^2(n)\right] - 4n\mathrm{E}\left[D(n)\right] + n^2 \\ &= 4\left[\mathrm{Var}\left[D(n)\right] + \left(\mathrm{E}\left[D(n)\right]\right)^2\right] - 4n\,\mathrm{E}\left[D(n)\right] + n^2 \\ &= 4\left[npq + n^2p^2\right] - 4n^2p + n^2 = 4npq + 4n^2p(p-1) + n^2 \\ &= n^2 - 4n(n-1)pq. \end{aligned} \tag{1.15}$$

Recordemos que $pq \in [0,1/4]$, por lo que

$$n^2 \geq \mathrm{R}_{XX}(n,n) \geq n. \tag{1.16}$$

Por otro lado, la autocovarianza da:

$$\begin{aligned} \mathrm{C}_{XX}(n,n) &= \mathrm{E}\left[X(n)X(n)\right] - \mathrm{E}\left[X(n)\right]\mathrm{E}\left[X(n)\right] = \mathrm{Var}\left[X(n)\right] = \mathrm{Var}\left[2D(n)-n\right] = 4\,\mathrm{Var}\left[D(n)\right] \\ &= 4npq. \end{aligned} \tag{1.17}$$

Un caso un poco más complicado es el siguiente:

$$
\begin{aligned}
\mathrm{R}_{XX}(n,n-1) = \mathrm{E}\left[X(n)X(n-1)\right] &= \sum_{x\in\mathcal{R}_{X(n-1)}} \left[(x+1)p+(x-1)q\right] x\,\mathrm{p}(x,n-1) \\
&= \sum_{x\in\mathcal{R}_{X(n-1)}} \left[x+p-q\right] x\,\mathrm{p}(x,n-1) \\
&= \sum_{x\in\mathcal{R}_{X(n-1)}} x^2\,\mathrm{p}(x,n-1) + (p-q)\sum_{x\in\mathcal{R}_{X(n-1)}} x\,\mathrm{p}(x,n-1) \\
&= \mathrm{E}\left[X^2(n-1)\right] + (p-q)\,\mathrm{E}\left[X(n-1)\right]. \qquad (1.18)
\end{aligned}
$$

Dado que $\mathrm{E}\left[X^2(n-1)\right] = \mathrm{R}_{XX}(n-1)$, ya sabemos que $\mathrm{E}\left[X^2(n-1)\right] = (n-1)^2 - 4(n-1)(n-2)pq$. Por otro lado,

$$
\mathrm{E}\left[X(n)\right] = \mathrm{E}\left[2D(n)-n\right] = 2np - n = n(2p-1) = n(p-q). \qquad (1.19)
$$

Por lo tanto,

$$
\mathrm{R}_{XX}(n,n-1) = (n-1)^2 - 4(n-1)(n-2)pq + (p-q)^2(n-1). \qquad (1.20)
$$

1.3.4. Generación con computadora

El siguiente código en Python produce una caminata aleatoria. El resultado se denomina una *realización* del proceso estocástico. La Fig. 1.3.4 muestra varias realizaciones.

randomwalk.py

```
import numpy as np
import matplotlib.pyplot as plt
rng = np.random.default_rng()

p = 0.5 #Probabilidad de un paso a la derecha
N = 99  #Número de pasos
derecha = (rng.random(N) < p)                #Paso a la der/izq = 1/0
saltos  = 2*(derecha-0.5)                    #Salto = +1/-1
x       = np.cumsum(saltos,dtype=np.int64)   #Posición
x       = np.hstack((np.zeros(1),x))         #Siempre empieza en 0
plt.step(np.arange(0,100),x)
```

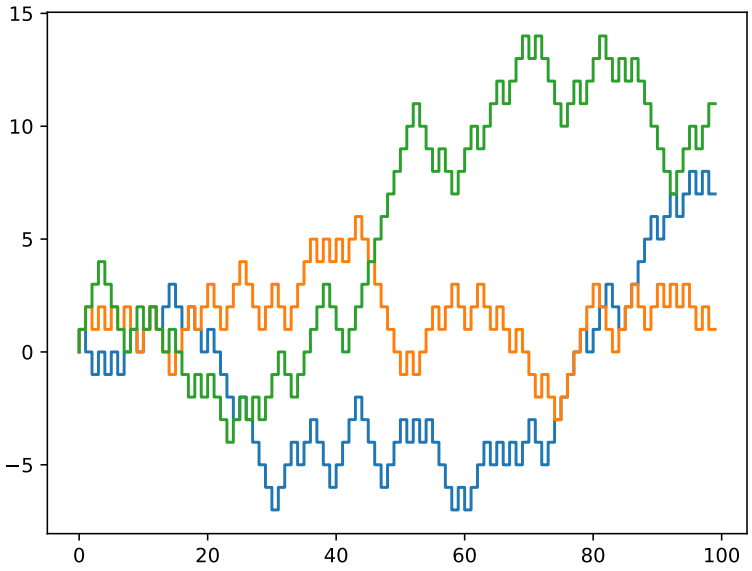

Figura 1.2: Ejemplo del resultado de ejecutar varias veces el código en Python randomwalk.py.

1.4. Caracterización de un proceso estocástico

En esta sección veremos varias propiedades que permiten caracterizar los procesos estocásticos.

1.4.1. Procesos de Markov

En un proceso de Markov, sólo es relevante el pasado más reciente. Más formalmente:

Definición 1.4.1 (Proceso de Markov). Se dice que un proceso estocástico es un *proceso de Markov* sii para todo $n \in \mathbb{N}$, toda secuencia $t_1 < t_2 < \cdots < t_{n-1} < t_n$ y todo $x \in \mathbb{R}$,

$$\mathrm{P}\big(X(t_n) \leq x |\, X(t_{n-1}), X(t_{n-2}), \cdots, X(t_1)\big) = \mathrm{P}\big(X(t_n) \leq x |\, X(t_{n-1})\big). \tag{1.21}$$

Caracterizar un proceso como Markoviano, facilita mucho el análisis. Es fácil ver que la caminata aleatoria es un proceso de Markov. Podríamos hacer una demostración formal (que no es difícil), pero nos limitaremos a tratar el caso de la estructura de árbol en la Fig. 1.3. A partir de dicha figura, es simple ver que

$$\begin{aligned}\mathrm{P}\big(X(n) = x |\, X(n-1) = y, X(n-2) = z\big) &= \begin{cases} p & x = z+2, y = z+1 \text{ o } x = z, y = z-1 \\ q & x = z-2, y = z-1 \text{ o } x = z, y = z+1 \\ 0 & \text{todo otro caso} \end{cases} \\ &= \mathrm{P}\big(X(n) = x |\, X(n-1) = y\big),\end{aligned}$$

donde la última igualdad se sigue del hecho que no es necesario conocer el valor de $X(n-2)$.

Basándonos, una vez más, en la Fig. 1.3, podemos escribir

$$\begin{aligned}&\mathrm{P}\big(X(n) = z |\, X(n-2) = z\big) = p \times q + q \times p = \\ &\mathrm{P}\big(X(n) = z |\, X(n-1) = z-1\big) \times \mathrm{P}\big(X(n-1) = z-1 |\, X(n-2) = z\big) + \\ &\mathrm{P}\big(X(n) = z |\, X(n-1) = z+1\big) \times \mathrm{P}\big(X(n-1) = z+1 |\, X(n-2) = z\big).\end{aligned}$$

Esta ecuación se puede generalizar, no sólo para la caminata aleatoria, sino para todo proceso de Markov:

Teorema 1.4.1 (Ecuación de Chapman-Kolmogorov). 1. Sea $X(t)$ un proceso de Markov con espacio de estados discreto. Luego, para todo tripe $t_1 < t_2 < t_3$,

$$\mathrm{P}\big(X(t_3) = x|\, X(t_1) = y\big) = \sum_{z \in \mathcal{R}_{X(t_2)}} \mathrm{P}\big(X(t_3) = x|\, X(t_2) = z\big) \times \mathrm{P}\big(X(t_2) = z|\, X(t_1) = y\big). \tag{1.22}$$

2. Sea $X(t)$ un proceso de Markov con espacio de estados continuo. Luego, para todo tripe $t_1 < t_2 < t_3$,

$$\mathrm{f}_{X(t_3)|X(t_1)}(x|y) = \int_{\mathbb{R}} \mathrm{f}_{X(t_3)|X(t_2)}(x|z) \times \mathrm{f}_{X(t_2)|X(t_1)}(z|y)dz. \tag{1.23}$$

1.4.2. Procesos estacionarios y ergódicos

Esencialmente, un proceso estacionario es aquel que *no cambia* con el tiempo. Un poco más formalmente:

Definición 1.4.2 (**Proceso estacionario**). Se dice que un proceso estocástico $X(t)$ es estacionario sii para todo $n \in \mathbb{N}$, toda secuencia $t_1 < t_2 < \cdots < t_n$, todo conjunto de valores $x_1, x_2, \cdots, x_n$ y todo τ tal que $t_i \in \mathbb{T} \Rightarrow t_i + \tau \in \mathbb{T}$,

$$\begin{aligned} \mathrm{P}\left(X(t_n + \tau) \leq x_n, X(t_{n-1} + \tau) \leq x_{n-1}, \cdots, X(t_1 + \tau) \leq x_1\right) = \\ \mathrm{P}\left(X(t_n) \leq x_n, X(t_{n-1}) \leq x_{n-1}, \cdots, X(t_1) \leq x_1\right). \end{aligned} \tag{1.24}$$

Un proceso estocástico estacionario tiene una propiedad interesante en relación a la autocorrelación:

$$\mathrm{R}_{XX}(t_1, t_2) = \mathrm{E}\left[X(t_1)X(t_2)\right] = \mathrm{E}\left[X(t_1 - t_2)X(0)\right] = \mathrm{R}_{XX}(t_1 - t_2, 0), \tag{1.25}$$

donde hemos usado la estacionariedad en la segunda igualdad. Es decir, en el caso de procesos estacionarios, *la autocorrelación depende sólo de la diferencia de los tiempos*. Esto simplifica mucho los cálculos, ya que la autocorrelación pasa a ser una función de una sola variable.

Si bien asumir que un proceso es estacionario simplifica enormemente el modelado, es una condición muy fuerte. De hecho, la caminata aleatoria no es un proceso estacionario. En efecto,

$$\mathrm{P}\left(X(1) = 0\right) = 0 \neq \mathrm{P}\left(X(0) = 0\right) = 1, \tag{1.26}$$

$$\mathrm{P}\left(X(2) = 0, X(1) = 1\right) = pq \neq \mathrm{P}\left(X(1) = 0, X(0) = 1\right) = 0, \tag{1.27}$$

donde a última desigualdad es verdadera si $p \neq 0$ y $q \neq 0$.

Una condición un tanto menos estricta es la siguiente:

Definición 1.4.3 (**Proceso estacionario en sentido amplio**). Se dice que un proceso estocástico $X(t)$ es estacionario en sentido amplio si y sólo si se cumplen las siguientes condiciones:

$$\mathrm{E}\left[X(t_1)\right] = \mathrm{E}\left[X(t_2)\right] \qquad \forall t_1, t_2 \in \mathbb{T}, \tag{1.28}$$

$$\mathrm{C}_{XX}(t_1, t_2) = \mathrm{C}_{XX}(t_1 - t_2, 0) \qquad \forall t_1, t_2 \in \mathbb{T}. \tag{1.29}$$

La segunda condición en la definición, captura el hecho que la autocorrelación depende sólo de la diferencia. Es decir, un proceso es estacionario en sentido amplio sii los primeros dos momentos no dependen del tiempo. Como ya hemos visto (Ecs. (1.15)-(1.20)), la caminata aleatoria tampoco es estacionaria en sentido amplio.

Cuando vimos cómo simular la caminata aleatoria, presentamos un programa que, cada vez que lo ejecutamos, produce una nueva *realización* del proceso estocástico. Supongamos que tenemos

un conjunto de realizaciones $\{X_1(t)\}_t$, $\{X_2(t)\}_t$, $\cdots$, $\{X_m(t)\}_t$, donde hemos usado $\{\cdot\}_t$ para que son varias series temporales. Un conjunto de este tipo se llama *ensamble*. Por las leyes de los grandes números, sabemos que podemos estimar el valor medio de un proceso estocástico $X(t)$ en un punto dado t_0 por el *promedio del ensamble*, esto es,

$$\mathrm{E}\left[X(t_0)\right] \approx \frac{1}{m}\sum_{k=1}^{m} X_k(t_0). \tag{1.30}$$

En el caso de un proceso estacionario, el valor esperado a la izquierda de esta ecuación no depende del tiempo. Si uno quisiera estimar dicho valor esperado, sería mucho fácil hacerlo a partir de una sola realización, en vez de necesitar muchas. Esa es la idea detrás del concepto de procesos ergódicos:

Definición 1.4.4 (**Proceso ergódico**)**.** Se dice que un proceso estocástico $X(t)$ estacionario en sentido amplio es *ergódico en media* sii

$$\lim_{N\to\infty} \frac{1}{N}\sum_{k=0}^{N-1} X(k) = \mathrm{E}\left[X(t)\right] \tag{1.31}$$

en el caso de $\mathbb{T} = \mathbb{N}^0$, y

$$\lim_{T\to\infty} \frac{1}{T}\int_0^T X(s)ds = \mathrm{E}\left[X(t)\right] \tag{1.32}$$

en el caso de $\mathbb{T} = \mathbb{R}^{\geq 0}$. En ambos casos, la convergencia es cuadrática media (ver Sección XXX).

Recordemos que la convergencia cuadrática implica, por ejemplo en el primer caso, que

$$\lim_{N\to\infty} \mathrm{E}\left[\left[\frac{1}{N}\sum_{k=0}^{N-1} X(k) - \mathrm{E}\left[X(t)\right]\right]^2\right] = 0. \tag{1.33}$$

No profundizaremos más sobre el concepto de ergodicidad aquí, ya que está fuera del alcance de estas notas.

1.4.3. Incrementos estacionarios e independientes

La caminata aleatoria no es estacionaria, ni siquiera en sentido amplio. ¿Qué característica de la caminata aleatoria podríamos usar para simplificar su descripción? Sabemos que la caminata procede en saltos. Más aún, los saltos siempre se realizan de la misma forma, es decir, con las mismas probabilidades. Esto motiva la siguiente

Definición 1.4.5 (**Incrementos estacionarios**)**.** Se dice que un proceso estocástico $X(t)$ tiene *incrementos estacionarios* sii para todo $t_1, t_2 \in \mathbb{T}$ y para todo τ tal que $t_1 + \tau, t_2 + \tau \in \mathbb{T}$, las variables aleatorias

$$(X(t_2) - X(t_1)) \text{ y } (X(t_2+\tau) - X(t_1+\tau))$$

tienen la misma distribución de probabilidades.

Hay otra característica de los saltos en la caminata aleatoria: que sea hacia la derecha o hacia la izquierda no depende de hacia dónde hayan sido los anteriores ni de hacia dónde serán los subsiguientes. Esto lo podemos generalizar como sigue

Definición 1.4.6 (**Incrementos independientes**)**.** Se dice que un proceso estocástico $\{X(t)\}_t$ tiene *incrementos independientes* sii para todo $n \in \mathbb{N}$ y todo conjunto de valores $t_0 < t_1 < \cdots < t_n \in \mathbb{T}$, las variables aleatorias $X(t_0)$, Δ_1, Δ_2, $\cdots$, Δ_n son independientes entre sí, donde

$$\Delta_k = X(t_k) - X(t_{k-1}). \tag{1.34}$$

Ya veremos que asumir incrementos estacionarios e independientes facilita mucho el trabajo con procesos estocásticos (aunque algo de esto ya hemos visto en el caso de la caminata aleatoria). Por lo pronto, veamos que

$$X(t_n) = X(t_0) + \sum_{k=1}^{n} \Delta_k. \tag{1.35}$$

Es decir, podemos escribir el proceso estocástico esencialmente como una suma variables aleatorias independientes y, si $t_k - t_{k-1} =$ constante, idénticamente distribuidas (i.i.d.) (salvo, tal vez, por $X(t_0)$).

La caminata aleatoria es un proceso de Markov y tiene incrementos independientes: ¿hay alguna relación entre las dos cosas?

Proposición 1.4.1 (Incrementos independientes $\Rightarrow$ Markov)**.** Sea $X(t)$ un proceso estocástico con incrementos independientes. Luego, $X(t)$ es un proceso de Markov.

Demostración. La idea de la prueba es la siguiente. Sean $n \in \mathbb{N}$, $t_1 < t_2 < \cdots < t_n \in \mathbb{T}$, $x_1, x_2, \cdots, x_n \in \mathbb{R}$. Luego:

$$\begin{aligned}
&\mathrm{P}\big(X(t_n) \leq x_n |\, X(t_{n-1}) = x_{n-1}, X(t_{n-2}) = x_{n-2}, \cdots, X(t_2) = x_2, X(t_1) = x_1\big) = \\
&\mathrm{P}\big(X(t_n) - X(t_{n-1}) \leq x_n - x_{n-1} |\, X(t_{n-1}) = x_{n-1}, X(t_{n-2}) = x_{n-2}, \cdots, X(t_2) = x_2, X(t_1) = x_1\big) = \\
&\mathrm{P}\big(\Delta_n \leq \delta_n |\, \Delta_{n-1} = \delta_{n-1}, \Delta_{n-2} = \delta_{n-2}, \cdots, \Delta_2 = \delta_2, X(t_1) = x_1\big) = \mathrm{P}\left(\Delta_n \leq \delta_n\right) = \\
&\mathrm{P}\left(X(t_n) - X(t_{n-1}) \leq x_n - x_{n-1}\right) = \mathrm{P}\big(X(t_n) \leq x_n |\, X(t_{n-1}) = x_{n-1}\big),
\end{aligned}$$

donde $\delta_k = x_k - x_{k-1}$ y en la tercera línea hemos usado la independencia de los incrementos. $\square$

1.5. Referencias

Buena parte del material en este capítulo fue tomado de las presentaciones para las clases de Probabilidad y Estadística, dictada en el Instituto Tecnológico de Buenos Aires, preparadas por Francisco Villaverde. También nos hemos basado en el libro de Bertsekas y Tsitsiklis [1] y de Fine [2].

Capítulo 2

Procesos de conteo

2.1. ¿Qué se cuenta?

En este capítulo, veremos dos ejemplos sencillos de procesos estocástico cuyos valores corresponden a contar cosas: personas en una fila, llamadas entrantes a un número telefónico, accesos a un servidor, partículas emitidas por una sustancia radiactiva, etc. Este tipo de procesos es caracterizado como sigue:

Definición 2.1.1 (Proceso de conteo). Se dice que un proceso estocástico $N(t)$ es un *proceso de conteo* sii:

1. $N(0) = 0$.
2. $N(t) \in \mathbb{N}^0$.
3. $s \leq t \Rightarrow N(s) \leq N(t)$.
4. $N(t) - N(s)$ es la cantidad de eventos en el intervalo $(s, t]$.

Los dos procesos de conteo que veremos a continuación, uno de tiempo discreto y otro de tiempo continuo, tienen muchas similaridades entre sí.

2.2. Proceso de Bernoulli

El proceso de Bernoulli es un proceso estocástico que nos es muy familiar. Supongamos que el tiempo procede de forma discreta (en horas, días, etc.). En cada instante de tiempo se realiza un experimento independiente que puede resultar en "éxito", con probabilidad p, o "fracaso", con probabilidad $q = 1 - p$. El proceso de Bernoulli $N(t)$ cuenta el número de éxitos a medida que pasa el tiempo. ¿Pueden reconocer qué distribución tiene $N(n)$? Debería ser simple: $N(n) \sim \text{Binomial}(n, p)$. ¿Por qué no lo llamaron proceso *binomial*? Sería posible, pero en breve explicaremos el por qué del nombre.

De manera más formal, podemos escribir:

Definición 2.2.1 (Proceso de Bernoulli). Un proceso estocástico de conteo $N(t)$ de tiempo discreto, $\mathbb{T} = \mathbb{N}^0$, es un *proceso de Bernoulli* sii para un $p \in (0, 1)$ se cumple:

1. Tiene incrementos independientes.
2. Los incrementos son estacionarios.
3. La probabilidad de que exactamente un evento ocurra en un intervalo de tiempo de 1 unidad es $\mathrm{P}\left(N(k+1) - N(k) = 1\right) = p$.

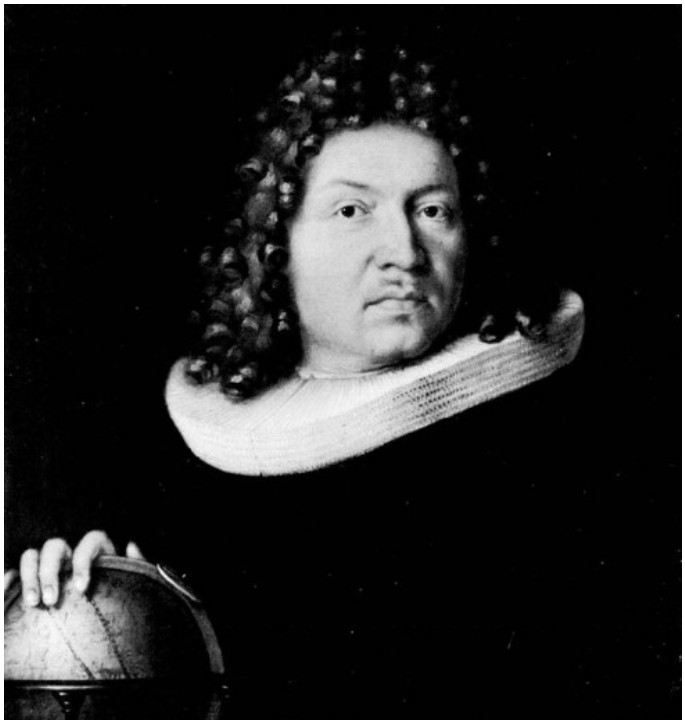

Figura 2.1: Jakob Bernoulli (1654-1705). Figura tomada de Wikimedia Commons.

4. La probabilidad de que más de un evento ocurra en un intervalo de tiempo de 1 unidad es $\mathrm{P}\left(N(k+1) - N(k) = m\right) = 0 \ \forall m > 1$.

En esta definición, cuando hablamos de "evento", nos referimos a un "éxito". Puede resultar confusa la nomenclatura (ya que hemos llamado eventos a otra cosa), pero es habitual en la literatura. Notemos, además, que al tratarse de un proceso con incrementos independientes, es un proceso de Markov.

2.2.1. Distribución marginal

Más arriba hicimos una descripción en palabras y otra más formal de un proceso de Bernoulli. ¿Coinciden ambas descripciones? Dicho de otra forma: ¿$N(n)$ tiene distribución binomial? Para ver esto, partamos de la definición. Podemos escribir

$$N(n) = N(0) + \sum_{k=1}^{n} \Delta_k, \qquad \text{con } \Delta_i = N(k) - N(k-1). \tag{2.1}$$

Dado que $N(n)$ es un proceso de conteo y, por tanto, $N(0) = 0$, esto se simplifica a

$$N(n) = \sum_{k=1}^{n} \Delta_k. \tag{2.2}$$

Como la definición dice que los incrementos son independientes y estacionarios, las variables aleatorias Δ_k son independientes y tienen todas la misma distribución, es decir, son variables aleatorias independientes e idénticamente distribuidas (**i.i.d.**). De los puntos 3 y 4 de la definición, se desprende que

$$\mathrm{P}\left(\Delta_k = s\right) = \begin{cases} 1-p & s = 0 \\ p & s = 1 \\ 0 & s \notin \{0,1\} \end{cases} \tag{2.3}$$

Además de 3 y 4, debemos usar el hecho que $N(k)$ es un proceso de conteo (y, por tanto, no decreciente con el tiempo) para asegurar que $\mathrm{P}(\Delta_k = s) = 0$ para $s < 0$. Ahora bien, esta descripción de los incrementos nos dice $\Delta_k \sim \text{Bernoulli}(p)$, y de ahí el nombre del proceso estocástico.

Para determinar la distribución de $N(n)$, debemos ir paso a paso:

- Para $n = 0$, sabemos $N(0) = 0$.
- Para $n = 1$, ya hemos visto que $N(1) = \Delta_1 \sim \text{Bernoulli}(p)$, por lo cual $\mathcal{R}_{N(1)} = \{0, 1\}$.
- Para $n = 2$, el recorrido se amplía ya que, como es claro, podemos contar hasta dos eventos: $\mathcal{R}_{N(1)} = \{0, 1, 2\}$. Luego:

  $$\mathrm{P}(N(2) = 0) = \mathrm{P}(\Delta_2 = 0, \Delta_1 = 0) = \mathrm{P}(\Delta_2 = 0)\,\mathrm{P}(\Delta_1 = 0) = (1-p)(1-p) = (1-p)^2$$

  por la independencia de los incrementos,

  $$\mathrm{P}(N(2) = 1) = \mathrm{P}(\Delta_2 = 1, \Delta_1 = 0) + \mathrm{P}(\Delta_2 = 0, \Delta_1 = 1) = p(1-p) + (1-p)p = 2p(1-p),$$
  $$\mathrm{P}(N(2) = 2) = \mathrm{P}(\Delta_2 = 1, \Delta_1 = 1) = pp = p^2,$$

  donde hemos usado el hecho que no puede haber más de un evento en cada intervalo unitario de tiempo. De estas fórmulas, es claro que $N(2) \sim \text{Binomial}(2, p)$.
- Procedemos por inducción. Supongamos que $N(n-1) \sim \text{Binomial}(n-1, p)$. No es difícil ver que $\mathcal{R}_{N(n)} = \{0, 1, \cdots, n\}$. Luego,

  $$\begin{aligned}
  \mathrm{P}(N(n) = 0) &= \mathrm{P}(\Delta_n = 0, N(n-1) = 0) = \mathrm{P}(\Delta_n = 0, N(n-1) - N(0) = 0) \\
  &= \mathrm{P}(\Delta_n = 0)\,\mathrm{P}(N(n-1) - N(0) = 0) = (1-p)(1-p)^{n-1} = (1-p)^n \\
  \mathrm{P}(N(n) = n) &= \mathrm{P}(\Delta_n = 1, N(n-1) = n-1) = \mathrm{P}(\Delta_n = 1, N(n-1) - N(0) = n-1) \\
  &= \mathrm{P}(\Delta_n = 1)\,\mathrm{P}(N(n-1) - N(0) = n-1) = p(1-p)^{n-1} = p^n
  \end{aligned}$$

  por la independencia de los incrementos (sí, $N(n-1) = N(n-1) - N(0)$ es un incremento). Para $1 \leq k \leq n-1$,

  $$\begin{aligned}
  \mathrm{P}(N(n) = k) &= \mathrm{P}(\Delta_2 = 1, N(n-1) = k-1) + \mathrm{P}(\Delta_2 = 0, N(n-1) = k) \\
  &= \mathrm{P}(\Delta_2 = 1)\,\mathrm{P}(N(n-1) = k-1) + \mathrm{P}(\Delta_2 = 0)\,\mathrm{P}(N(n-1) = k) \\
  &= p\binom{n-1}{k-1} p^{k-1}(1-p)^{n-k} + (1-p)\binom{n-1}{k} p^k (1-p)^{n-1-k} \\
  &= \frac{(n-1)!}{(n-k)!(k-1)!} p^k (1-p)^{n-k} + \frac{(n-1)!}{(n-k-1)!k!} p^k (1-p)^{n-k} \\
  &= \frac{(n-1)!}{(n-k-1)!(k-1)!} p^k (1-p)^{n-k} \left[\frac{1}{(n-k)} + \frac{1}{k}\right] \\
  &= \frac{(n-1)!}{(n-k-1)!(k-1)!} p^k (1-p)^{n-k} \left[\frac{k + (n-k)}{(n-k)k}\right] \\
  &= \frac{n!}{(n-k)!k!} p^k (1-p)^{n-k}.
  \end{aligned}$$

  Es decir, $N(n) \sim \text{Binomial}(n, p)$. Por inducción, esto es válido para todo $n \in \mathbb{N}$.

Si bien fue algo trabajoso partir de la definición formal del proceso de Bernoulli, esto nos permitió sentar las bases del siguiente resultado

Proposición 2.2.1 (Suma de Bernoulli y de binomiales independientes). Dos resultados:

1. Sean $X_k \sim \text{Bernoulli}(p)$, $k = 1, 2, \cdots, n$, i.i.d. Luego

   $$\sum_{k=1}^{n} X_k \sim \text{Binomial}(n, p). \tag{2.4}$$

2. Sean $Y_k \sim \text{Binomial}(n_k, p)$, $k = 1, 2, \cdots, m$, independientes. Luego

$$\sum_{k=1}^{m} Y_k \sim \text{Binomial}(\sum_k n_k, p). \tag{2.5}$$

Tal vez el segundo resultado resulte extraño. Pero podemos pensar los Y_k de dos formas distintas (y equivalentes). Una forma es como incrementos (independientes) de un proceso de Bernoulli. La otra forma, gracias al primer resultado, es como suma de n_k variables Bernoulli i.i.d.

2.2.2. Tiempos entre eventos

Nos podemos preguntar cuánto tiempo pasa entre un evento y el siguiente. Para más claridad, definamos:

1. T_k es el tiempo hasta el k-ésimo evento, $k \geq 1$. Esto implica que:

$$N(T_k) = k, \tag{2.6}$$

$$N(t) = k - 1 \qquad \forall t < T_k. \tag{2.7}$$

Por conveniencia, vamos a escribir $T_0 = 0$.

2. τ_k es el tiempo entre el evento $(k-1)$-ésimo y el k-ésimo, si $k > 1$, y $\tau_1 = T_1$. Es decir que

$$N(t) - N(T_k) = 0 \qquad \forall t < T_k + \tau_k, \tag{2.8}$$

$$T_n = \sum_{k=1}^{n} \tau_k. \tag{2.9}$$

Por las Ecs. (2.6)-(2.6),

$$\begin{aligned}
\mathrm{P}\left(T_k = n\right) &= \mathrm{P}\left(N(n) = k, N(n-1) = k-1\right) \\
&= \mathrm{P}\big(N(n) = k |\, N(n-1) = k-1\big)\, \mathrm{P}\left(N(n-1) = k-1\right) = p \binom{n-1}{k-1} p^{k-1}(1-p)^{n-k} \\
&= \binom{n-1}{k-1} p^k (1-p)^{n-k}.
\end{aligned} \tag{2.10}$$

Es decir que T_k tiene distribución binomial negativa, lo cual es razonable ya que se trata del número de experimentos necesarios hasta alcanzar el k-ésimo resultado en una serie de experimentos independientes, todos con igual éxito. Esto se escribe: $T_k \sim \text{BinoNeg}(k, p)$. En el caso particular de T_1, estamos en presencia de una variable geométrica ($\text{BinoNeg}(1, p) = \text{Geo}(p)$): $\tau_1 = T_1 \sim \text{Geo}(p)$.

Respecto de los tiempos entre eventos, la Ec. (2.8) junto al hecho que los incrementos del proceso de Bernoulli son estacionarios, implica que

$$\begin{aligned}
1 - F_{\tau_k}(s) &= \mathrm{P}\left(\tau_k > s\right) = \mathrm{P}\left(N(T_k + s) - N(T_k) = 0\right) = \mathrm{P}\left(N(T_{k-1} + s) - N(T_{k-1}) = 0\right) \\
&= \mathrm{P}\left(\tau_{k-1} > s\right) = 1 - F_{\tau_{k-1}}(s).
\end{aligned}$$

Esto quiere decir que τ_k y τ_{k-1} tienen la misma distribución. En general, todos los τ_k son idénticamente distribuidos con $\tau_k \sim \text{Geo}(p)$. Por otro lado, dado que los incrementos del proceso de Bernoulli son independientes, si $k_a \neq k_b$ para $a \neq b$

$$\begin{aligned}
&\mathrm{P}\left(\tau_{k_1} > s_1, \tau_{k_2} > s_2, \cdots, \tau_{k_m} > s_m\right) = \\
&\mathrm{P}\left(N(T_{k_1} + s_1) - N(T_{k_1}) = 0, N(T_{k_2} + s_2) - N(T_{k_2}) = 0, \cdots, N(T_{k_m} + s_m) - N(T_{k_m}) = 0\right) = \\
&\prod_{l=1}^{m} \mathrm{P}\left(N(T_{k_l} + s_l) - N(T_{k_l}) = 0\right) = \prod_{l=1}^{m} \mathrm{P}\left(\tau_{k_l} > s_l\right).
\end{aligned}$$

De esto se desprende que los tiempos entre eventos son independientes entre sí.

Resumiendo: si se tiene un proceso estocástico de Bernoulli con probabilidad de ocurrencia de eventos p, sabemos que

1. los tiempos entre eventos τ_k son variables aleatorias i.i.d. con distribución $\mathrm{Geo}(p)$, y
2. el tiempo hasta el k-ésimo evento T_k tiene distribución $\mathrm{BinoNeg}(k, p)$.

La primera conclusión puede, de hecho, usarse para definir el proceso de Bernoulli de otra forma:

Definición 2.2.2 (**Proceso de Bernoulli. Segunda versión.**)**.** Un proceso estocástico de conteo $N(t)$ de tiempo discreto, $\mathbb{T} = \mathbb{N}^0$, es un *proceso de Bernoulli* sii, para un $p \in (0, 1)$, los tiempos entre eventos τ_k son variables aleatorias i.i.d. con distribución $\mathrm{Geo}(p)$.

¿Dos definiciones para una misma cosa? Eso sólo es posible si son equivalentes:

Proposición 2.2.2. Ambas definiciones del proceso de Bernoulli son equivalentes.

Ya hemos demostrado que la primera definición implica la versión 2. Sólo nos falta probar que esta última implica la primera. Eso no es difícil, pero un poco engorroso en los detalles, por lo que no lo haremos aquí. La idea básica es que la independencia de los incrementos de $N(t)$ se sigue de la independencia de los tiempos entre eventos y su estacionariedad es consecuencia de que los τ_k sean idénticamente distribuidos.

Antes de continuar, podemos notar que, de yapa, hemos conseguido el siguiente resultado:

Proposición 2.2.3 (Suma de variables aleatorias geométricas independientes)**.** Sean $\tau_k \sim \mathrm{Geo}(p)$ i.i.d. Luego,

$$\sum_{k=1}^{n} \tau_k \sim \mathrm{BinoNeg}(n, p). \tag{2.11}$$

2.2.3. Un ejemplo errado

Se transmiten bits sobre un sistema de comunicación sin memoria, esto es, un sistema en que la probabilidad de que un bit sea recibido con error en extremo de recepción es independiente de lo que le suceda a los demás bits. La probabilidad de error de cada bit es siempre la misma, $p = 10^{-5}$.

1. ¿Cuál es la probabilidad de que haya al menos 1 error en los primeros 10 bits recibidos?
2. ¿Cuál es la probabilidad de que haya al menos 5 errores en los primeros 10^6 bits?
3. ¿Cuál es el tiempo medio hasta al tercer error?

Por la descripción, es claro que $N(k) =$ número de bits con error hasta el k-ésimo bit recibido es un proceso de Bernoulli. Para la primer pregunta tenemos $N(10) \sim \mathrm{Binomial}(10, 10^{-5})$. Por lo tanto,

$$\mathrm{P}\left(N(10) \leq 1\right) = 1 - \mathrm{P}\left(N(10) = 0\right) = 1 - (1 - 10^{-5})^{10} \approx 0.0000999955 \approx 0.0001.$$

En la segunda pregunta, tenemos $N(10^6) \sim \mathrm{Binomial}(10^6, 10^{-6})$ y

$$\begin{aligned}\mathrm{P}\left(N(10^6) \geq 5\right) = 1 - \mathrm{P}\left(N(10^6) \leq 4\right) &= 1 - \sum_{k=0}^{4} \binom{10^6}{k} (10^{-5})^k (1 - 10^{-5})^{10^6 - k} \\ &\approx 1 - \sum_{k=0}^{4} \frac{10^k}{k!} e^{-10} \approx 0.9708,\end{aligned}$$

donde hemos usado la aproximación Poisson a la binomial.

Para contestar la tercera pregunta, sólo debemos entender que $T_3 \sim \mathrm{BinoNeg}(3, 10^{-5})$. Luego, $\mathrm{E}\left[T_3\right] = 3/10^{-5} = 3 \times 10^5$.

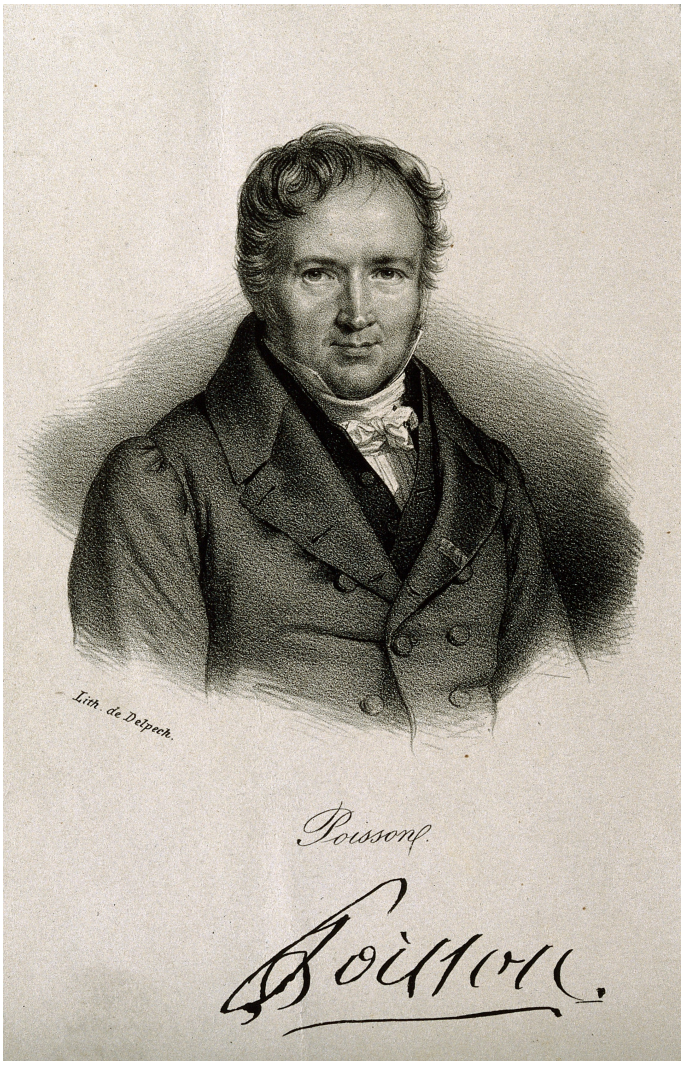

Figura 2.2: Siméon Denis Poisson (1781-1840). Figura tomada de Wikimedia Commons.

2.3. Proceso de Poisson

Partimos directamente de la siguiente

Definición 2.3.1 (Proceso de Poisson). Un proceso estocástico de conteo $N(t)$ de tiempo continuo, $\mathbb{T} = \mathbb{R}^{\geq 0}$, es un *proceso de Poisson* sii para un $\lambda > 0$, llamado la *tasa del proceso*, se cumplen las siguientes condiciones:

1. Tiene incrementos independientes.

2. Los incrementos son estacionarios.

3. La probabilidad de que exactamente un evento ocurra en un intervalo de tiempo de longitud $h > 0$ es $\mathrm{P}\left(N(t+h) - N(t) = 1\right) = \lambda h + \mathrm{o}(h)$.

4. La probabilidad de que más de un evento ocurra en un intervalo de tiempo de longitud $h > 0$ es $\mathrm{P}\left(N(t+h) - N(t) > 1\right) = \mathrm{o}(h)$.

Esta definición guarda muchas similitudes con la definición del proceso Bernoulli. Ya veremos que ello no es casualidad. Primero, volvamos a recordar que el hecho que sea un proceso de incrementos independientes implica que es Markov. También recordemos qué significa la *o chiquita*:

Definición 2.3.2 (o chiquita). Se dice que $f(h) = \mathrm{o}(h)$ sii

$$\lim_{h\to 0} \frac{f(h)}{h} = 0. \tag{2.12}$$

Es fácil ver que la combinación lineal de funciones que son $\mathrm{o}(h)$ también es $\mathrm{o}(h)$. Operacionalmente:

$$a\,\mathrm{o}(h) + b\,\mathrm{o}(h) = \mathrm{o}(h) \qquad \forall a, b \in \mathbb{R}. \tag{2.13}$$

Con estos conceptos, ya deberíamos estar en posición de explicar por qué el proceso lleva el nombre de Poisson.

2.3.1. Distribución marginal

Vamos a utilizar una nomenclatura que nos facilite el trabajo en el caso de este proceso. Llamaremos

$$p_n(t) = \mathrm{P}\left(N(t) = n\right). \tag{2.14}$$

Comencemos con $n = 0$. Si $N(t+h) = 0$, no tiene que haber ocurrido ningún evento hasta $t+h$. En particular, no debe haber ocurrido ningún evento hasta tiempo t. Es decir:

$$N(t+h) = 0 \Rightarrow N(t) = 0 \tag{2.15}$$
$$\{N(t+h) = 0\} \subseteq \{N(t) = 0\} \tag{2.16}$$
$$\{N(t+h) = 0\} \cap \{N(t) = 0\} = \{N(t+h) = 0\} \tag{2.17}$$

Podemos escribir, entonces,

$$\begin{aligned}\mathrm{P}\left(N(t+h) = 0\right) &= \mathrm{P}\left(N(t+h) = 0, N(t) = 0\right) = \mathrm{P}\big(N(t+h) = 0 |\, N(t) = 0\big)\,\mathrm{P}\left(N(t) = 0\right)\\ p_0(t+h) &= \mathrm{P}\big(N(t+h) = 0 |\, N(t) = 0\big) p_0(t).\end{aligned} \tag{2.18}$$

Si $N(t) = 0$, para que $N(t+h) = 0$ no debe ocurrir ningún evento en el intervalo $(t, t+h]$: ni uno ni más de uno. Por las condiciones 3 y 4 en la definición (e implícitamente por 1 y 2):

$$p_0(t+h) = \mathrm{P}\left(N(t+h) - N(t) = 0\right) p_0(t) \tag{2.19}$$
$$p_0(t+h) = \left[1 - \mathrm{P}\left(N(t+h) - N(t) = 1\right) - \mathrm{P}\left(N(t+h) - N(t) > 1\right)\right] p_0(t) \tag{2.20}$$
$$p_0(t+h) = \left[1 - \lambda h - \mathrm{o}(h)\right] p_0(t), \tag{2.21}$$

donde hemos usado el hecho que $\mathrm{o}(h) + \mathrm{o}(h) = \mathrm{o}(h)$. De esta última ecuación, obtenemos

$$\frac{p_0(t+h) - p_0(t)}{h} = -\lambda p_0(t) - \frac{\mathrm{o}(h)}{h} p_0(t). \tag{2.22}$$

Haciendo $h \to 0$,

$$\frac{dp_0(t)}{dt} = -\lambda p_0(t). \tag{2.23}$$

¡Una ecuación diferencial para la probabilidad!

Veamos ahora el caso de p_n para un $n \in \mathbb{N}$. Como en el caso de $n = 0$, fijamos un tiempo $t+h$ y nos preguntamos por la probabilidad de $N(t+h) = n$. ¿Cuánto podría haber valido $N(t)$? Puede

haber sido $N(t) = n$, $N(t) = n - 1$, o $N(t) = m$ con $m < n - 1$. Por un razonamiento análogo al anterior, tenemos que

$$\begin{aligned}
\mathrm{P}\left(N(t+h) = n\right) &= \sum_{k=0}^{n} \mathrm{P}\left(N(t+h) = n, N(t) = k\right) \\
&= \sum_{k=0}^{n} \mathrm{P}\big(N(t+h) = n | \, N(t) = k\big) \, \mathrm{P}\left(N(t) = k\right) \\
p_n(t+h) &= \sum_{k=0}^{n} \mathrm{P}\big(N(t+h) = n | \, N(t) = k\big) p_k(t) && (2.24) \\
&= \sum_{k=0}^{n} \mathrm{P}\left(N(t+h) - N(t) = n - k\right) p_k(t). && (2.25)
\end{aligned}$$

Veamos cada uno de los términos en la sumatoria del lado derecho:

- Para $k = n$, ya hemos visto que

$$\mathrm{P}\left(N(t+h) - N(t) = 0\right) = 1 - \lambda h - \mathrm{o}(h). \tag{2.26}$$

- Para $k = n - 1$, por la condición 3 de la definición de Poisson:

$$\mathrm{P}\left(N(t+h) - N(t) = 1\right) = \lambda h - \mathrm{o}(h). \tag{2.27}$$

- Por la condición 4 de la definición, para $m > 1$

$$\mathrm{P}\left(N(t+h) - N(t) = m\right) \leq \mathrm{P}\left(N(t+h) - N(t) > 1\right) = \mathrm{o}(h). \tag{2.28}$$

Usando estos hechos y recordando que la combinación lineal de $\mathrm{o}(h)$ es $\mathrm{o}(h)$,

$$p_n(t+h) = \left[1 - \lambda h\right] p_n(t) + \lambda h p_{n-1}(t) + \mathrm{o}(h), \tag{2.29}$$

$$\frac{p_n(t+h) - p_n(t)}{h} = -\lambda p_n(t) + \lambda p_{n-1}(t) + \frac{\mathrm{o}(h)}{h}. \tag{2.30}$$

Una vez más, hacemos tender h a 0:

$$\frac{dp_n(t)}{dt} = -\lambda p_n(t) + \lambda p_{n-1}(t). \tag{2.31}$$

Resumiendo, tenemos un sistema de (infinitas) ecuaciones diferenciales acopladas:

$$\frac{dp_0(t)}{dt} = -\lambda p_0(t), \tag{2.32}$$

$$\frac{dp_n(t)}{dt} = -\lambda p_n(t) + \lambda p_{n-1}(t) \qquad n \in \mathbb{N}. \tag{2.33}$$

¿Cómo se resuelve esto? Con paciencia. Se puede demostrar que

$$p_n(t) = \frac{(\lambda t)^n}{n!} e^{-\lambda t} \qquad \forall n \in \mathbb{N}^0. \tag{2.34}$$

Es decir que $N(t) \sim \mathrm{Poisson}(\lambda t)$. ¡Y de ahí el nombre del proceso! Y también este es el motivo por el cual λ es denominado una tasa. Supongamos que t es el tiempo medido en segundos y que $N(t)$ representa el número de accesos a un servidor. Para que la distribución de $N(t)$ tenga sentido, λt

debe ser adimensional, por lo que $[\lambda] = \mathrm{s}^{-1}$. Es decir que λ da la tasa media de accesos al servidor por segundo.

La demostración de la Ec. (2.34) es sencilla, pero un poco larga. Más simple es verificar que es correcta (y un teorema de unicidad de la solución debería completar nuestra confianza en el resultado). Para $n = 0$,

$$\frac{dp_0(t)}{dt} = \frac{d}{dt}\left(e^{-\lambda t}\right) = -\lambda e^{-\lambda t} = -\lambda p_0(t). \tag{2.35}$$

Para $n > 0$,

$$\frac{dp_n(t)}{dt} = \frac{d}{dt}\left(\frac{(\lambda t)^n}{n!}e^{-\lambda t}\right) = n\frac{\lambda^n t^{n-1}}{n!}e^{-\lambda t} - \lambda\frac{(\lambda t)^n}{n!}e^{-\lambda t} \tag{2.36}$$

$$= \lambda p_{n-1}(t) - \lambda p_n(t). \tag{2.37}$$

De yapa, hemos demostrado un resultado interesante sobre sumas de variables aleatorias Poisson independientes. Claro, tomemos $t_0 = 0 < t_1 < t_2 < \cdots < t_m$ y definamos $\Delta_k = N(t_k) - N(t_{k-1})$. Dado que los incrementos son independientes, las Δ_k son independientes. Además,

$$\mathrm{P}\left(\Delta_k = n\right) = \mathrm{P}\left(N(t_k) - N(t_{k-1}) = n\right) = \mathrm{P}\left(N(t_k - t_{k-1}) - N(0) = n\right) = \mathrm{P}\left(N(t_k - t_{k-1}) = n\right),$$

por lo que $\Delta_k \sim \mathrm{Poisson}(\lambda(t_k - t_{k-1}))$. Finalmente, también sabemos que

$$N(t_m) = \sum_{k=1}^{m} \Delta_k \sim \mathrm{Poisson}(\lambda t_m).$$

Dado que lo valores de t_k son arbitrarios, hemos demostrado la siguiente

Proposición 2.3.1 (Suma de variables aleatorias Poisson independientes)**.** Sean $X_k \sim \mathrm{Poisson}(\lambda_k)$, $k = 1, 2, \cdots, m$, variables independientes. Luego:

$$\sum_{k=1}^{m} X_k \sim \mathrm{Poisson}(\sum_k \lambda_k). \tag{2.38}$$

2.3.2. Tiempos entre eventos

Definamos τ_k y T_k como en el proceso de Bernoulli (ver Ecs. (2.6)-(2.9)), es decir, τ_k es el tiempo entre el evento $(k-1)$-ésimo y el k-ésimo, y T_k es el tiempo hasta este último. ¿Qué significa que $\tau_k > t$? Quiere decir que no se ha producido ningún evento en el intervalo $(T_k, T_k + t]$, es decir, $N(T_k + t) - N(T_k) = 0$. Por lo tanto,

$$1 - F_{\tau_k}(t) = \mathrm{P}\left(N(T_k + t) - N(T_k) = 0\right) = \mathrm{P}\left(N(t) - N(0) = 0\right) = \mathrm{P}\left(N(t) = 0\right) = e^{-\lambda t} \tag{2.39}$$

$$F_{\tau_k}(t) = 1 - e^{-\lambda t}. \tag{2.40}$$

Esto es, $\tau_k \sim \mathrm{Expo}(\lambda)$. Como k era arbitrario, la misma distribución vale para todos los tiempos entre eventos. Al igual que en el caso del proceso de Bernoulli, es fácil ver que los τ_k son independientes. Es decir, los tiempos entre eventos son variables aleatorias i.i.d. con distribución exponencial. Este hecho da lugar a la siguiente definición alternativa:

Definición 2.3.3 (**Proceso de Poisson. Segunda versión.**)**.** Un proceso estocástico de conteo $N(t)$ de tiempo continuo, $\mathbb{T} = \mathbb{R}^{\geq 0}$, es un *proceso de Poisson* sii, para un $\lambda > 0$, los tiempos entre eventos τ_k son variables aleatorias i.i.d. con distribución $\mathrm{Expo}(\lambda)$.

Por coherencia, es necesario el siguiente resultado:

Proposición 2.3.2. Ambas definiciones del proceso de Poisson son equivalentes.

Ya hemos demostrado que la primera definición implica la versión 2. Para no irnos por las ramas, obviamos la prueba del otro sentido.

Para determinar la distribución de los T_k, notemos que T_k es mayor a t sii $N(t) < k$. Por lo tanto,

$$1 - F_{T_k}(t) = \mathrm{P}\left(T_k > t\right) = \mathrm{P}\left(N(t) < k\right) = \sum_{m=0}^{k-1} \frac{(\lambda t)^m}{m!} e^{-\lambda t} \qquad t > 0, \tag{2.41}$$

$$F_{T_k}(t) = \begin{cases} 0 & t \leq 0 \\ 1 - \sum\limits_{m=0}^{k-1} \frac{(\lambda t)^m}{m!} e^{-\lambda t} & t > 0. \end{cases} \tag{2.42}$$

Puede parecer que la densidad es complicada, pero no es así. Para $t > 0$,

$$\begin{aligned} f_{T_k}(t) &= \left[\sum_{m=0}^{k-1} m \frac{\lambda^m t^{m-1}}{m!}\right] e^{-\lambda t} - \left[\sum_{m=0}^{k-1} \frac{\lambda^m t^m}{m!}\right] \lambda e^{-\lambda t} \\ &= \left[\sum_{m=1}^{k-1} \frac{\lambda^m t^{m-1}}{(m-1)!}\right] e^{-\lambda t} - \left[\sum_{m=0}^{k-1} \frac{\lambda^{m+1} t^m}{m!}\right] e^{-\lambda t} \\ &= \left[\sum_{l=0}^{k-2} \frac{\lambda^{l+1} t^l}{(l)!}\right] e^{-\lambda t} - \left[\sum_{m=0}^{k-1} \frac{\lambda^{m+1} t^m}{m!}\right] e^{-\lambda t} \\ &= \frac{\lambda^k t^{k-1}}{(k-1)!} e^{-\lambda t}. \end{aligned} \tag{2.43}$$

¿Qué distribución es esta? Tiene varios nombres. Uno de ellos es el siguiente:

Definición 2.3.4 (Distribución de Erlang)**.** Una variable aleatoria $X \sim \mathrm{Erlang}(k, \lambda)$, con $k \in \mathbb{N}$ y $\lambda > 0$, si su función de densidad de probabilidad viene dada por

$$f_X(t) = \begin{cases} 0 & t < 0 \\ \frac{\lambda^k t^{k-1}}{(k-1)!} e^{-\lambda t} & t > 0. \end{cases} \tag{2.44}$$

La distribución Erlang es un caso particular de la distribución Gama:

Definición 2.3.5 (Distribución de Erlang)**.** Una variable aleatoria $X \sim \Gamma(\alpha, \lambda)$, con $\alpha, \lambda > 0$, si su función de densidad de probabilidad viene dada por

$$f_X(t) = \begin{cases} 0 & t < 0 \\ \frac{\lambda^\alpha t^{\alpha-1}}{\Gamma(\alpha)} e^{-\lambda t} & t > 0, \end{cases} \tag{2.45}$$

donde la función Γ viene definida por

$$\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt. \tag{2.46}$$

Para $k \in \mathbb{Z}$, $\Gamma(k) = (k-1)!$.

En esta sección, entre otras cosas, también hemos conseguido demostrar el siguiente resultado:

Proposición 2.3.3 (Suma de variables aleatorias exponenciales independientes)**.** Sean $\tau_k \sim \mathrm{Expo}(\lambda)$ i.i.d. Luego,

$$\sum_{k=1}^{n} \tau_k \sim \mathrm{Erlang}(k, \lambda). \tag{2.47}$$

2.3.3. Relación entre los procesos de Bernoulli y de Poisson

Supongamos que tenemos un proceso de Poisson de parámetro λ. Discreticemos el tiempo de la siguiente manera:

1. $\Delta t \ll 1$ (muy chiquito),
2. $t_k = k\Delta t$.

Por las condiciones 3 y 4 de la definición del proceso de Poisson,

$$\mathrm{P}\left(N(t_k) - N(t_{k-1}) = 1\right) = \lambda\Delta t + \mathrm{o}(\Delta t) \approx \lambda\Delta t \tag{2.48}$$
$$\mathrm{P}\left(N(t_k) - N(t_{k-1}) > 1\right) = \mathrm{o}(\Delta t) \approx 0 \tag{2.49}$$
$$\mathrm{P}\left(N(t_k) - N(t_{k-1}) = 0\right) = 1 - \lambda\Delta t - \mathrm{o}(\Delta t) \approx 1 - \lambda\Delta t \tag{2.50}$$
$$\tag{2.51}$$

Es decir que $p_{\Delta t} = \lambda\Delta t$ es aproximadamente la probabilidad de que suceda un evento en un intervalito de tiempo. Si llamamos $M(n)$ al proceso de Bernoulli con probabilidad $p_{\Delta t}$, $M(n)$ representa el número de eventos hasta t_n. Por tanto,

$$\mathrm{P}\left(N(t_n) = k\right) \approx \mathrm{P}\left(M(n) = k\right) = \binom{n}{k} p_{\Delta t}^k (1 - p_{\Delta t})^{n-k} \approx \frac{(np_{\Delta t})^k}{k!} e^{-np_{\Delta t}} = \frac{(\lambda t)^k}{k!} e^{-\lambda t}. \tag{2.52}$$

Este enredo circular sólo nos dice que:

1. Un proceso de Poisson puede ser aproximado, en cierta medida, por un proceso de Bernoulli.
2. Más importante: un proceso de Poisson es un límite de tiempo continuo del proceso de Bernoulli.

2.3.4. Un ejemplo infantil

Supongamos que tiempo entre cambios de pañales consecutivos de un bebé sigue una ley exponencial de media 4 horas y que los tiempos son independientes entre sí:

1. ¿Cuál es la probabilidad de que pasen más de 24 horas hasta que se cambie el cuarto pañal?
2. ¿Cuál es la probabilidad de que en un mes típico de 30 días se usen más de 200 pañales?
3. ¿Cuál es la probabilidad de que entre el primer y el 6 pañal cambiado pase a lo sumo 1 día?

Dada la definición (versión 2) del proceso de Poisson, sabemos que $N(t)$ = el número de pañales cambiados hasta tiempo t es un proceso de Poisson con tasa $\lambda = 0.25$ 1/h. Para la primer pregunta tenemos $N(24) \sim \text{Poisson}(6)$ y

$$\mathrm{P}\left(N(24) < 4\right) = \sum_{k=0}^{3} \frac{6^k}{k!} e^{-6} = 0.1512.$$

Para la segunda pregunta, consideramos $N(720) \sim \text{Poisson}(180)$. La respuesta es:

$$\mathrm{P}\left(N(720) > 200\right) = 1 - \sum_{k=0}^{200} \frac{180^k}{k!} e^{-180} = 0.0652.$$

Usando la aproximación normal con corrección por continuidad:

$$\mathrm{P}\left(N(720) > 200\right) \approx 1 - \Phi\left(\frac{200.5 - 180}{\sqrt{180}}\right) = 1 - \Phi\left(1.5280\right) = 0.0633.$$

La tercer pregunta pide $\mathrm{P}\left(T_6 - T_1 \leq 24\right)$ (¡ojo!: estamos trabajando todo en horas). Esto es:

$$\begin{aligned}\mathrm{P}\left(T_6 - T_1 \leq 24\right) &= \mathrm{P}\left(\sum_{k=2}^{6} \tau_k \leq 24\right) = \mathrm{P}\left(\sum_{k=1}^{5} \tau_k \leq 24\right) = \mathrm{P}\left(T_5 \leq 24\right) = 1 - \sum_{k=0}^{4} \frac{6^k}{k!} e^{-6} \\ &= 0.7149,\end{aligned}$$

donde hemos usado el hecho que los tiempos entre eventos están idénticamente distribuidos; alternativamente, podríamos haber usado lo que hemos demostrado sobre suma de variables exponenciales i.i.d.

2.4. Generación con computadora

El siguiente código en Python produce una secuencia de estados de un proceso de Poisson a partir de la tasa λ. La Fig. 2.4 muestra una realización.

poisson.py

```python
import numpy as np
rng = np.random.default_rng()
import matplotlib.pyplot as plt

# Genera una realización de un Proceso de Poisson
# rate es lambda, la tasa del proceso
# maxtime es el máximo tiempo simulado
# n es la cantidad de instantes considerados
def simulpoisson(rate,maxtime):

    t = 0; N = 0
    time = [t];
    X = [N]
    while t < maxtime:
        time.append(t)
        X.append(N)
        tau = rng.exponential(1/rate)
        t = t+tau
        N = N + 1

    time.append(maxtime)
    X.append(N-1)

    return time, X


#Ejemplo de uso
rate = 0.1
maxt = 100
time, X = simulpoisson(rate,maxt)
plt.step(time,X,where='post')
```

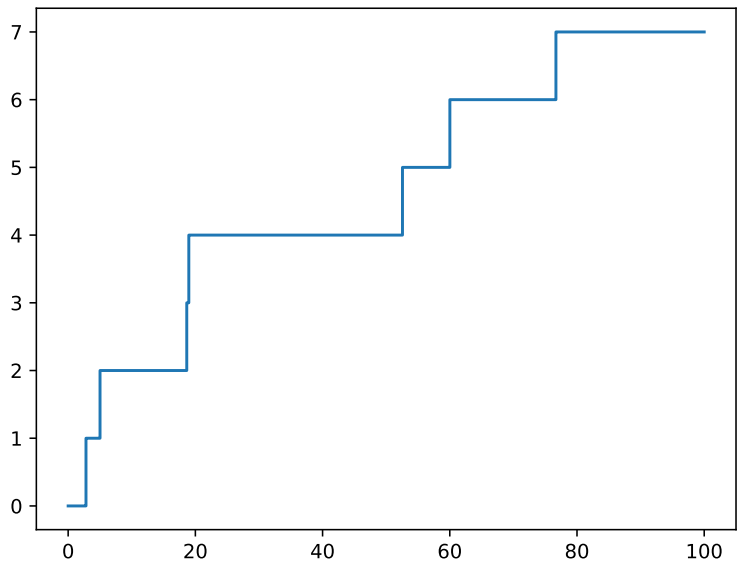

Figura 2.3: Ejemplo del resultado de ejecutar el código en Python poisson.py.

2.5. Referencias

Buena parte del material en este capítulo fue tomado de las presentaciones para las clases de Probabilidad y Estadística, dictada en el Instituto Tecnológico de Buenos Aires, preparadas por Francisco Villaverde. También nos hemos basado en el libro de Bertsekas y Tsitsiklis [1].

Capítulo 3

Cadenas de Markov

Figura 3.1: Andrey Andreyevich Markov (1856-1922). Figura tomada de Wikimedia Commons.

Las cadenas de Markov son herramientas fundamentales en el modelado de procesos en ingeniería, física, química y biología. En estas notas, nos concentraremos en las cadenas de Markov de tiempo discreto y espacio de estados finito.

3.1. Cadenas de Markov de tiempo discreto

Comencemos por la definición que nos dice, esencialmente, que una cadena de Markov es un proceso de Markov con un espacio de estados discreto:

Definición 3.1.1 (Cadenas de Markov de tiempo discreto). Una *cadena de Markov* de tiempo discreto es un proceso de Markov con un espacio de estado $\mathbb{E}$ discreto y un espacio de parámetro $\mathbb{T} = \mathbb{N}^0$. Sin pérdida de generalidad, podemos escribir $\mathbb{E} = \mathbb{N}$ en el caso de un espacio enumerable de estados, y $\mathbb{E} = \{1, 2, \cdots, n\}$ si dicho espacio es finito.

¿Algún ejemplo de una cadena de Markov? La caminata aleatoria: un proceso de Markov con espacio de estados discreto.

Es conveniente utilizar la siguiente notación para una cadena de Markov $X(n)$:

$$p_i(n) = \mathrm{P}\left(X(n) = i\right), \tag{3.1}$$

$$p_{ij}(n) = \mathrm{P}\big(X(n+1) = j \,|\, X(n) = i\big). \tag{3.2}$$

Los valores $p_i(n)$ dan la función de masa de probabilidad de $X(n)$ y, por tanto, debe cumplir

$$\sum_{i \in \mathbb{E}} p_i(n) = 1. \tag{3.3}$$

Cada $p_{ij}(n)$ es una *probabilidad de transición del estado i al estado j en un solo paso desde el instante n*. Como siempre algo sucede en cada instante de tiempo, tenemos que

$$\sum_{j \in \mathbb{E}} p_{ij}(n) = 1. \tag{3.4}$$

Es decir, siempre se salta a algún lado.

Es más simple escribir la función de masa de probabilidades de $X(n)$ como un "vector"

$$\vec{p}(n) = \begin{pmatrix} p_1(n) & p_2(n) & \cdots \end{pmatrix}, \tag{3.5}$$

y agrupar todas las probabilidades de transición en una *matriz de probabilidades de transición de un solo paso*

$$\mathbf{P}(n) = \begin{pmatrix} p_{11}(n) & p_{12}(n) & \cdots \\ p_{21}(n) & p_{22}(n) & \cdots \\ \vdots & \vdots & \ddots \end{pmatrix}, \tag{3.6}$$

donde las filas suman 1.

La ecuación de Chapman-Kolmogorov nos dice que:

$$p_j(n+1) = \sum_{i \in \mathbb{E}} p_{ij}(n) p_i(n). \tag{3.7}$$

En forma matricial, podemos escribir:

$$\vec{p}(n+1) = \vec{p}(n)\,\mathbf{P}(n). \tag{3.8}$$

Así tenemos, por ejemplo,

$$\vec{p}(n) = \vec{p}(n-1)\,\mathbf{P}(n-1) = \vec{p}(n-2)\,\mathbf{P}(n-2)\,\mathbf{P}(n-1). \tag{3.9}$$

Continuando de este modo, es fácil ver que:

$$\vec{p}(n) = \vec{p}(0)\,\mathbf{P}(0)\,\mathbf{P}(1)\,\cdots\,\mathbf{P}(n-1). \tag{3.10}$$

Es decir, para conocer la distribución de probabilidades de $X(n)$, basta con conocer la distribución original y las probabilidades de transición en cada instante de tiempo.

En muchas ocasiones se puede trabajar con un modelo simplificado en el que las probabilidades de transición no varían con el tiempo:

Definición 3.1.2 (Cadenas de Markov homogéneas)**.** Se dice que una cadena de Markov es homogénea sii

$$p_{ij}(n) = p_{ij}(k) \qquad \forall i, j \in \mathbb{E}, \forall n, k \in \mathbb{N}^0. \tag{3.11}$$

En el caso de cadenas homogéneas, escribimos simplemente $p_{ij}(n) = p_{ij}$ y $\mathbf{P}(n) = \mathbf{P}$. La ecuación de Chapman-Kolmogorov se simplifica enormemente:

$$\vec{p}(n) = \vec{p}(0)\,\mathbf{P}^n. \tag{3.12}$$

Podemos decir que $\mathbf{P}^n$ contiene las *probabilidades de transición en n pasos*. Llamaremos p_{ij}^n al elemento en la fila i y columna j de $\mathbf{P}^n$, es decir, a la probabilidad de transición del estado i al estado j en n pasos. Por completitud, definamos

$$p_{ij}^0 = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases} \tag{3.13}$$

y $\mathbf{P}^0 = \mathbf{I}$, la matriz identidad.

3.2. Generación con computadora

El siguiente código en Python produce una secuencia de estados de una cadena de Markov a partir de una matriz de probabilidades de transición y un estado inicial. La Fig. 3.2 muestra una realización.

markovchain.py

```python
import numpy as np
rng = np.random.default_rng()
import matplotlib.pyplot as plt

# Genera una realización de una cadena de Markov
# P es la matriz de transición
# x0 es el estado inicial
# n es la cantidad de instantes considerados
def simulmarkov(P,x0,n):

    M = P.shape[0]
    X = np.zeros(n+1,dtype=np.int64)
    X[0]=x0
    for k in range(n):
        X[k+1] = rng.choice(M,p=P[X[k]-1,:])+1
    return X

#Ejemplo de uso
Pv = np.array([[0,1.0,0],[2/3,0,1/3],[2/3,1/3,0]])
xi = 1
n  = 40
M  = Pv.shape[0]
X  = simulmarkov(Pv, xi, n)

# plot
fig, ax = plt.subplots()
ax.stairs(X, linewidth=2.5)
ax.set(xlim=(0.1, n+0.9),
       ylim=(0, M+1), yticks=np.arange(0, M+1))
```

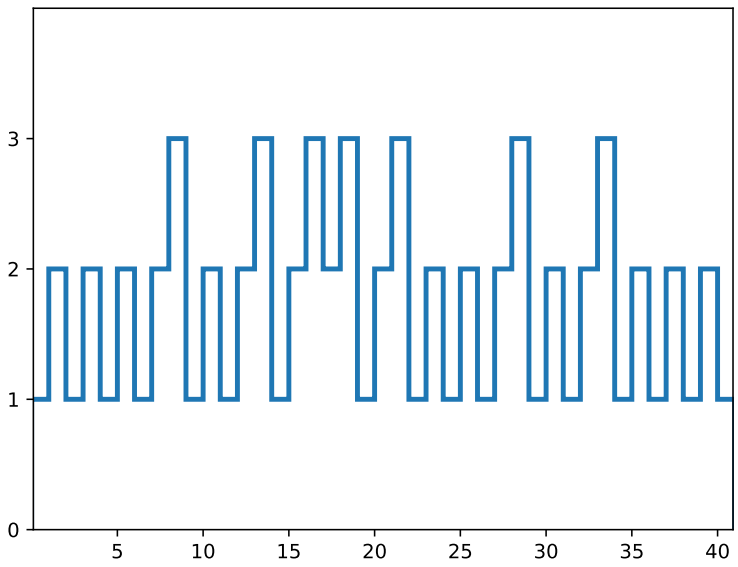

Figura 3.2: Ejemplo del resultado de ejecutar el código en Python markovchain.py.

3.3. Algunos ejemplos

Los siguientes ejemplos servirán para colocar las ideas en orden.

3.3.1. El vendedor viajero

La región de ventas de un vendedor la componen tres ciudades A, B y C. Nunca vende en la misma ciudad en días seguidos. Si vende en la ciudad A, entonces al día siguiente vende en la ciudad B. Sin embargo, si vende en una de las dos ciudades B o C, entonces al día siguiente la probabilidad de vender en A es el doble de la de vender en la restante.

Llamemos $X(n)$ a la ciudad visitada en el n-ésimo día. Dado que sólo visita tres ciudades, el espacio de estados es finito y podemos escribirlo como $\mathbb{E} = \{1, 2, 3\}$, donde asumimos que hemos ordenado, *arbitrariamente*, las ciudades en orden alfabético: $A \to 1$, $B \to 2$, $C \to 3$. Observemos que la próxima ciudad a ser visitada depende sólo de la ciudad en que el vendedor se encuentra actualmente: esto implica que es un proceso de Markov. Las probabilidades de transición son:

1. *Nunca vende en la misma ciudad en días seguidos*$\Rightarrow p_{ii} = 0$ $i = 1, 2, 3$.

2. *Si vende en la ciudad A, entonces al día siguiente vende en la ciudad B*$\Rightarrow p_{12} = 1$, $p_{1,3} = 0$.

3. *Sin embargo, si vende en una de las dos ciudades B o C, entonces al día siguiente la probabilidad de vender en A es el doble de la de vender en la restante*$\Rightarrow$

$$p_{21} = 2p_{23}, \qquad p_{31} = 2p_{32}.$$

. Como sabemos que

$$p_{21} + p_{22} + p_{23} = 1, \qquad p_{31} + p_{32} + p_{33} = 1,$$

es fácil calcular

$$p_{21} = p_{31} = \frac{2}{3}, \qquad p_{23} = p_{32} = \frac{1}{3}.$$

Resumiendo, podemos escribir

$$\mathbf{P} = \begin{pmatrix} 0 & 1 & 0 \\ \frac{2}{3} & 0 & \frac{1}{3} \\ \frac{2}{3} & \frac{1}{3} & 0 \end{pmatrix}. \tag{3.14}$$

Es fácil verificar que las filas suman 1.

En general, es más sencillo describir cadenas de Markov pequeñas como esta mediante un *diagrama de estados*, esto es, un grafo donde los nodos son los estados y las flechas entre estados representan transiciones posibles. A cada flecha se le asigna como etiqueta o peso el valor de la probabilidad de transición correspondiente. La Fig. 3.3 muestra el diagrama para este ejemplo.

Antes de continuar con el siguiente ejemplo, observemos que existe una probabilidad no nula de que el viajante llegue desde cualquier ciudad a cualquier otra ciudad en un cierto número de pasos. De hecho, $\mathbf{P}^4$ tiene todos sus elementos positivos:

$$\mathbf{P}^4 = \frac{1}{81} \begin{pmatrix} 42 & 18 & 21 \\ 26 & 49 & 6 \\ 26 & 48 & 7 \end{pmatrix}. \tag{3.15}$$

En particular, todas ciudades son "visitables".

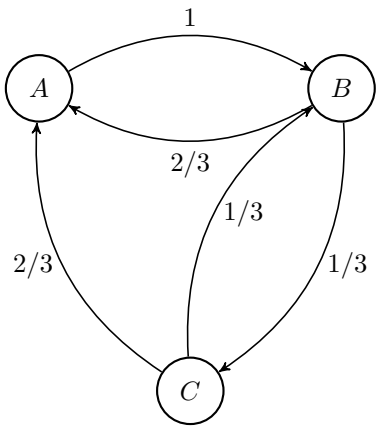

Figura 3.3: Diagrama de estados de la cadena de Markov del vendedor viajante.

3.3.2. El bebé

Un profesor de probabilidad ha decidido modelar a su bebé con una cadena de Markov. Él supone que sólo puede estar en 3 estados:

1. Come (Co).
2. Hace sus necesidades (Ca).
3. Duerme (Du).

El diagrama de estados se encuentra en la Fig. 3.4. La matriz de probabilidades de transición es

$$\mathbf{P} = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}. \tag{3.16}$$

Es fácil comprobar que $\mathbf{P}^4 = \mathbf{P}$. Es que, de hecho, el bebé va pasando de estado en estado y los mismos se repiten periódicamente.

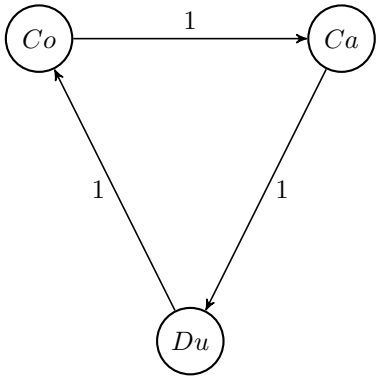

Figura 3.4: Diagrama de estados de la cadena de Markov del vendedor viajante.

3.3.3. La vida

En un momento más filosófico, el profesor de estadística se da cuenta que la un ser humano puede ser descripto por dos estados: Vivo (1) y Muerto (2). Él decide modelar la dinámica de esos dos estados como una cadena de Markov, en la cual cada año puede morir con una probabilidad p o continuar vivo con probabilidad $1 - p$. Dado que no cree en otras vidas ni en zombis, asume que quien está muerto, seguirá muerto. La Fig. 3.5 muestra el diagrama de estados. La matriz de probabilidades de transición es

$$\mathbf{P} = \begin{pmatrix} 1 & 0 \\ p & 1-p \end{pmatrix} \tag{3.17}$$

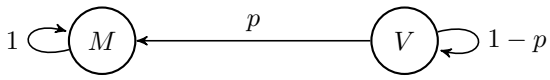

Figura 3.5: Un modelo simple de vida.

El estado M es un *estado absorbente* ya que de él no se puede salir. El estado B, por el contrario, es un *estado transitorio* ya que, después de un tiempo, no se puede volver a él.

3.3.4. La vida más compleja

Nuestro profesor tuvo un resfrío fuerte y decidió cambiar un poco el modelo agregando un estado: Muerto (1), Enfermo (2) y Sano (3). La Fig. 3.6 muestra el diagrama de estados, junto con los valores que estimó en la parte de atrás de un pañuelo de papel. La matriz de probabilidades de transición es

$$\mathbf{P} = \begin{pmatrix} 1.00 & 0.00 & 0.00 \\ 0.05 & 0.15 & 0.80 \\ 0.01 & 0.09 & 0.90 \end{pmatrix}, \tag{3.18}$$

Observemos que ahora son dos los estados transitorios, E y S.

3.3.5. Juego de pelota

Alicia (1), Beto (2), Carolina (3) y Diego (4) juegan a pasarse una pelota de goma. Se sabe lo siguiente:

- Nunca nadie se queda la pelota para si mismo.
- Alicia, Beto y Carolina nunca devuelven la pelota, pasándosela entre ellos.

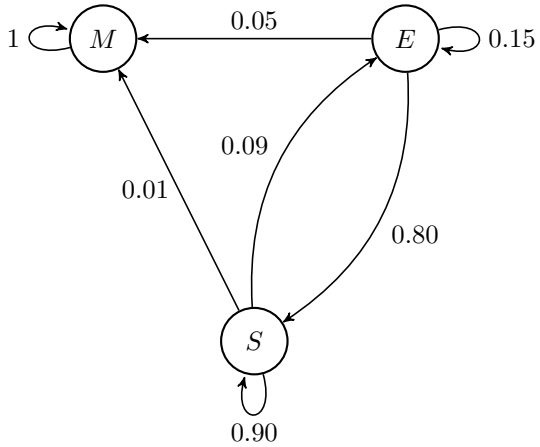

Figura 3.6: Un modelo complejo de vida.

- Cada vez que tiene la pelota, Alicia (Beto) se la pasa a Beto (Alicia) con probabilidad 0.8.
- Carolina le pasa la pelota con igual probabilidad a Alicia y a Beto.
- Diego le pasa la pelota con igual probabilidad a cada a Alicia y a Carolina.

Si modelamos quién tiene la pelota en cada instante como una cadena de Markov, no es difícil ver que la matriz de probabilidades de transición viene dada por

$$\mathbf{P} = \begin{pmatrix} 0 & \frac{4}{5} & \frac{1}{5} & 0 \\ \frac{4}{5} & 0 & \frac{1}{5} & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 \end{pmatrix}, \tag{3.19}$$

y el diagrama de estados es como el que se representa en la Fig. 3.7.

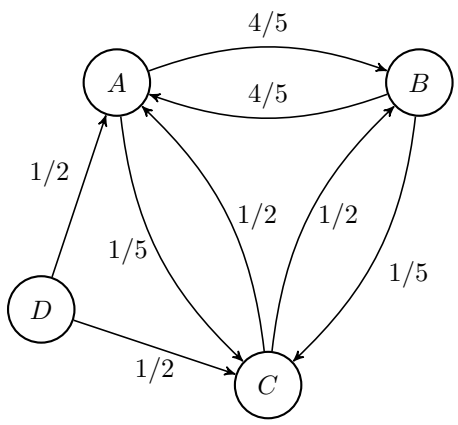

Figura 3.7: Juego de pelota.

En este caso, D es un estado transitorio y A, B y C son estados *recurrentes* (vuelven a ocurrir todo el tiempo). Si bien no hay ningún estado absorbente, A, B y C forman un *conjunto o clase absorbente de estados*: una vez que se alcanza a ese grupete, no se puede salir.

3.4. Clasificación de los estados

En los ejemplos de la sección anterior, hemos presentado varios tipos distintos de estados. Comencemos con la siguiente

Definición 3.4.1 (Accesibilidad y comunicabilidad)**.** Decimos que el estado j es *accesible* desde el estado i sii $p_{ij}^n > 0$ para algún $n \in \mathbb{N}^0$. Dos estados i y j se comunican entre sí cuando j es accesible desde i e i es accesible desde j.

No es complicado ver que la comunicabilidad es una propiedad reflexiva, transitiva y la que cada estado estado está comunicado con él mismo (ya que $p_{ii}^0 = 1$). Este hecho permite asignarle a los estados que se comunican entre sí a lo que, técnicamente, se llama una clase. Sin entrar en los detalles, podemos tomarlo como

Definición 3.4.2 (Cadena de Markov irreducible)**.** Se dice que dos estados que se comunican entre sí están en la misma *clase*. Si todos los estados de una cadena de Markov están en la misma clase, se dice que la cadena es *irreducible*.

Veamos los ejemplos:

1. Vendedor viajero: todos los estados son accesibles entre sí y la cadena es irreducible. Esto es claro ya que $\mathbf{P}^4$ tiene todos sus elementos positivos.
2. El bebé: todos los estados son accesibles entre sí y la cadena de Markov es irreducible. Sin embargo, aquí no tenemos $\mathbf{P}^n$ con todos sus elementos positivos para ningún n: hay una periodicidad.
3. La vida: M y V no están en la misma clase, ya que V no es accesible desde M.
4. La vida compleja: M y $\{E, S\}$ son dos clases disjuntas, ya que ni E ni S son accesibles de M.
5. Juego de pelota: nuevamente hay dos clases, $\{D\}$ y $\{A, B, C\}$ ya que D no es accesible desde ninguno de los demás estados.

Al introducir los ejemplos, dividimos los estados en dos tipos, recurrentes y transitorios. Más formalmente,

Definición 3.4.3 (Estados transitorios y recurrentes)**.** Llamemos r_i a la probabilidad de que, partiendo del estado i, el proceso de Markov va a volver al estado i. Decimos que i es:

- un *estado recurrente* si $r_i = 1$ (o sea, seguro que vuelve);
- un *estado transitorios* si $r_i < 1$.

Llamemos N_i al número de veces que el proceso de Markov visita el estado i. Cada vez que se llega al estado i, existe una probabilidad r_i de volver a visitarlo, ya que el proceso se renueva (dado que es Markoviano y homogéneo). Si i es transitorio, $1 - r_i > 0$, es decir, existe una probabilidad positiva de no visitar nuevamente ese estado. Entonces

$$\mathrm{P}\left(N_i = k\right) = (1 - r_i) r_i^{k-1} \qquad k \geq 1. \tag{3.20}$$

Es decir, $N_i \sim \mathrm{Geo}(r_i)$ y, por tanto, $\mathrm{E}\left[N_i\right] = (1 - r_i)^{-1} < \infty$. Por el contrario, en el caso en que i es recurrente, cada vez que es visitado, existirá una probabilidad $r_i = 1$ de ser visitado nuevamente. Esto implica que será visitado infinitas veces, esto es, $\mathrm{E}\left[N_i\right] = \infty$. Dicho de otra forma, i es recurrente sii $\mathrm{E}\left[N_i\right] = \infty$.

Observemos que otra forma de escribir N_i es

$$N_i = \sum_{k=1}^{\infty} V_i^k, \text{ con } V_i^k = \begin{cases} 1 & \text{si } X_k = i \\ 0 & \text{si } X_k \neq i \end{cases} \tag{3.21}$$

Luego,

$$\mathrm{E}\left[N_i \middle| X_0 = i\right] = \mathrm{E}\left[\sum_{k=1}^{\infty} V_i^k \middle| X_0 = i\right] = \sum_{k=1}^{\infty} \mathrm{E}\left[V_i^k \middle| X_0 = i\right] = \sum_{k=1}^{\infty} p_{ii}^k. \tag{3.22}$$

Esta ecuación y la discusión previa demuestran la siguiente

Proposición 3.4.1 (Caracterización de estados recurrentes y transitorios)**.** El i es:

- *recurrente* si $\sum\limits_{k=1}^{\infty} p_{ii}^k = +\infty$;
- *transitorio* si $\sum\limits_{k=1}^{\infty} p_{ii}^k < +\infty$.

¿Para qué nos sirve este resultado? En principio, para demostrar que dos estados que se comunican comparte la propiedad de ser recurrentes o transitorios:

Proposición 3.4.2. Sean i y j dos estados en la misma clase. Entonces, o los dos son transitorios o los dos son recurrentes.

Demostración. Supongamos que i es recurrente y j se comunica con i. Es decir, existen n y m tales que $p_{ij}^n > 0$ (j accesible desde i) y $p_{ji}^m > 0$ (i accesible desde j). Luego, $p_{jj}^{m+k+n} \geq p_{ji}^m p_{ii}^k p_{ij}^n$ y

$$\sum_{k=1}^{\infty} p_{jj}^{m+k+n} \geq p_{ji}^m p_{ij}^n \sum_{k=1}^{\infty} p_{ii}^k = \infty. \tag{3.23}$$

Por la proposición anterior, j es también recurrente. □

Todos los ejemplos que hemos visto hasta ahora son de cadenas de Markov finitas. En ese caso, ¿pueden ser todos los estados transitorios? Supongamos que hay m estados, $\{1, 2, \cdots, m\}$, y partimos del estado 1. Ese estado puede no ser visitado nunca más. En algún momento, se arriba al estado 2. Del mismo modo, tal vez esa sea la última visita a dicho estado. Y así continuamos, hasta que hemos recorrido todos los estados y nunca más volveremos a ninguno de ellos... ¡Pero eso no es posible! Por lo tanto, tampoco podemos tener todos los estados transitorios en una cadena de Markov finita.

Entonces, volviendo a los ejemplos:

1. Vendedor viajero: dado que es una cadena irreducible y finita, todos los estados deben ser recurrentes.

2. El bebé: nuevamente, irreducibilidad y finitud implican recurrencia de todos los estados.

3. La vida: no es difícil ver que M es un estado recurrente, ya que $p_{11}^k = 1$ para todo $k > 0$ y, por tanto $\sum_k p_{11}^k = \infty$. ¿Y qué hay de V? Multiplicando algunas veces la matriz de probabilidades de transición, se puede ver que $p_{22}^k = p^k$. Como

$$\sum_{k=0} p^k = \frac{1}{1-p} < \infty, \tag{3.24}$$

   llegamos a la conclusión que estar vivo es un estado transitorio.

4. La vida compleja: un análisis similar muestra que M es recurrente y que E y S son transitorios.

5. Juego de pelota: claramente D es transitorio porque $p_{44}^k = 0$. Tomemos luego el caso de A: $p_{11}^1 = 0$ y $p_{11}^2 \geq p_{12}p_{21} = (4/5)^2$. En general, $p_{11}^n \geq (4/5)^2 p_{11}^{n-2}$. Por lo tanto:

$$\sum_{n=2}^{\infty} p_{11}^n \geq \left(\frac{4}{5}\right)^2 \sum_{n=2}^{\infty} p_{11}^{n-2} = \left(\frac{4}{5}\right)^2 \sum_{k=0}^{\infty} p_{11}^k = \left(\frac{4}{5}\right)^2 + \sum_{k=2}^{\infty} p_{11}^k \tag{3.25}$$

$$\sum_{n=2}^{\infty} p_{11}^n \geq \left(\frac{4}{5}\right)^2 + \sum_{k=2}^{\infty} p_{11}^k \tag{3.26}$$

Esta desigualdad es sólo posible si la suma de las probabilidades es infinita. Por lo tanto, A es recurrente. B y C, que están en la misma clase que A, también son recurrentes.

La última clasificación de estados que necesitamos aquí es la siguiente:

Definición 3.4.4 (Estados periódicos y positivamente recurrentes)**.** Dado un i, podemos determinar m_i, esto es, el entero más grande tal que $p_{ii}^n = 0$ cuando n no es divisible por m_i. Si $m_i = 1$, decimos que es un *estado aperiódico*. Si $m_i > 1$, decimos que i es un *estado periódico* con período m_i.

Un estado es *positivamente recurrente* si el valor esperado del tiempo hasta retornar a i partiendo de i es finito.

Los resultados en las siguientes dos proposiciones son importantes, pero no presentamos aquí su demostración para no extendernos demasiado:

Proposición 3.4.3 (Periodicidad y recurrencia positiva son propiedades de clase)**.** Sean i y j dos estados que se comunican entre sí. Luego:

1. $m_i = m_j$, por lo que o son ambos periódicos con el mismo período o aperiódicos.

2. i es positivamente recurrente sii j lo es.

Proposición 3.4.4 (Recurrencia positiva en cadenas finitas)**.** Todos los estados recurrentes en una cadena de Markov finita son positivamente recurrentes.

Volvamos al ejemplo del bebé. Unas simples multiplicaciones muestran que $\mathbf{P}^3 = \mathbf{I}$. Por tanto, todos los estados son periódicos con período 3.

3.5. Distribución a largo plazo

Volvamos al ejemplo del vendedor viajante. Ya vimos que $\mathbf{P}^4$ tiene todos sus elementos positivos. Vamos a continuar con potencias de $\mathbf{P}$, redondeando los resultados a 6 decimales:

$$\mathbf{P}^4 = \begin{pmatrix} 0.518519 & 0.222222 & 0.259259 \\ 0.320988 & 0.604938 & 0.074074 \\ 0.320988 & 0.592593 & 0.086420 \end{pmatrix},$$

$$\mathbf{P}^{10} = \begin{pmatrix} 0.410405 & 0.429203 & 0.160392 \\ 0.393063 & 0.463869 & 0.143068 \\ 0.393063 & 0.463852 & 0.143085 \end{pmatrix},$$

$$\mathbf{P}^{20} = \begin{pmatrix} 0.400200 & 0.449600 & 0.150200 \\ 0.399900 & 0.450200 & 0.149900 \\ 0.399900 & 0.450200 & 0.149900 \end{pmatrix},$$

$$\mathbf{P}^{20} = \begin{pmatrix} 0.400000 & 0.450000 & 0.150000 \\ 0.400000 & 0.450000 & 0.150000 \\ 0.400000 & 0.450000 & 0.150000 \end{pmatrix}.$$

Lo que observamos es que los elementos de cada columna aparentan converger al mismo valor. Y en verdad se puede demostrar que esto es así, es decir, que

$$\lim_{n\to\infty} \mathbf{P}^n = \begin{pmatrix} 0.40 & 0.45 & 0.15 \\ 0.40 & 0.45 & 0.15 \\ 0.40 & 0.45 & 0.15 \end{pmatrix}. \tag{3.27}$$

Pero esto tiene otra consecuencia interesante. Supongamos que la distribución inicial es $\vec{p}(0) = \big(a, b, c\big)$. Luego:

$$\begin{aligned} \lim_{n\to\infty} \vec{p}(n) &= \lim_{n\to\infty} \vec{p}(0)\mathbf{P}^n = \vec{p}(0) \lim_{n\to\infty} \mathbf{P}^n \\ &= \big(a, b, c\big) \begin{pmatrix} 0.40 & 0.45 & 0.15 \\ 0.40 & 0.45 & 0.15 \\ 0.40 & 0.45 & 0.15 \end{pmatrix} \\ &= \big(0.40(a+b+c),\, 0.45(a+b+c),\, 0.15(a+b+c)\big) \qquad (3.28) \\ &= \big(0.40,\, 0.45,\, 0.15\big), \qquad (3.29) \end{aligned}$$

donde hemos usado el hecho que $a+b+c = 1$. Es decir, a la larga, los estados tienen esa distribución de probabilidades. ¡Y lo más loco es que no depende de la distribución inicial $\vec{p}(0)$! (no asumimos nada respecto a, b, c). Esto motiva la siguiente

Definición 3.5.1 (**Distribución a largo plazo**)**.** Dada una cadena de Markov, se define la *distribución a largo plazo o estacionaria* como

$$\vec{\pi} = \lim_{n\to\infty} \vec{p}(n), \tag{3.30}$$

si ese límite existe y es independiente de la distribución inicial.

¿Siempre existe una distribución a largo plazo? El ejemplo del bebé nos demuestra que no. Tomando nuevamente $\vec{p}(0) = \big(a, b, c\big)$,

$$\begin{aligned} \vec{p}(1) &= \big(c, a, b\big), \\ \vec{p}(2) &= \big(b, c, a\big), \\ \vec{p}(3) &= \big(a, b, c\big), \\ \vec{p}(4) &= \big(c, a, b\big), \\ \vec{p}(5) &= \big(b, c, a\big), \\ \vec{p}(6) &= \big(a, b, c\big), \\ \ddots &= \ddots \end{aligned}$$

Vemos, claramente, que no existe distribución a largo plazo.

En el caso del vendedor viajante tenemos una cadena irreducible con todos los estados recurrentes aperiódicos. Por otra parte, en el caso del bebé tenemos una cadena irreducible con todos los estados recurrentes y periódicos. Eso nos da la intuición de por qué el siguiente resultado es correcto, aunque omitimos aquí la demostración:

Teorema 3.5.1 (**Convergencia a una distribución estacionaria**)**.** Una cadena de Markov irreducible con todos los estados positivamente recurrentes y aperiódicos tiene una única distribución estacionaria o a largo plazo.

Este teorema es muy importante ya que nos da condiciones suficientes para la existencia de una distribución estacionaria. Sin embargo, operativamente es un poco engorroso. Afortunadamente, para cadenas de Markov finitas tenemos una forma operativamente más simple de mostrar que las condiciones del teorema se cumplen:

Teorema 3.5.2 (**Matrices regulares**)**.** Considere una cadena de Markov finita. Si existe un $n \geq 1$ tal que todos los elementos $\mathbf{P}^n$ son positivos, entonces la cadena es irreducible con los estados positivamente recurrentes y aperiódica. En este caso, se dice que $\mathbf{P}$ es *regular*.

Tampoco daremos aquí una demostración de este teorema que, si bien simple, es un poco larga. Notemos, sin embargo, que en el caso del vendedor viajante habíamos observado que $\mathbf{P}$ es regular ya que $\mathbf{P}^4$ tiene todos sus valores positivos. Los últimos dos teoremas nos dicen, entonces, que existe una distribución estacionaria en el ejemplo del vendedor viajante.

Es muy importante notar que los teoremas nos dan condiciones suficientes, pero no necesarias. Veamos el modelo simple de vida:

$$\begin{aligned}
\mathbf{P}^1 &= \begin{pmatrix} 1 & 0 \\ 1-p & p \end{pmatrix}, \\
\mathbf{P}^2 &= \begin{pmatrix} 1 & 0 \\ 1-(1-p)^2 & (1-p)^2 \end{pmatrix}, \\
\mathbf{P}^3 &= \begin{pmatrix} 1 & 0 \\ 1-(1-p)^3 & (1-p)^3 \end{pmatrix}, \\
\ddots &= \ddots \\
\mathbf{P}^n &= \begin{pmatrix} 1 & 0 \\ 1-(1-p)^n & (1-p)^n \end{pmatrix}, && (3.31) \\
\lim_{n\to\infty} \mathbf{P}^n &= \begin{pmatrix} 1 & 0 \\ 1 & 0 \end{pmatrix}. && (3.32)
\end{aligned}$$

Debería resultar claro que existe una distribución a largo plazo, ya que a largo plazo se termina en el estado muerto con probabilidad 1.

Tampoco cumple las condiciones de los teoremas el modelo complejo de vida, pero el resultado es el mismo: la muerte a largo plazo. Es más interesante, en este sentido, el ejemplo del juego de pelota, en el cual tenemos:

$$\begin{aligned}
\mathbf{P}^1 &= \begin{pmatrix} 0 & \frac{4}{5} & \frac{1}{5} & 0 \\ \frac{4}{5} & 0 & \frac{1}{5} & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 \end{pmatrix}, \\
\mathbf{P}^2 &= \begin{pmatrix} 0.740000 & 0.100000 & 0.160000 & 0 \\ 0.100000 & 0.740000 & 0.160000 & 0 \\ 0.400000 & 0.400000 & 0.200000 & 0 \\ 0.250000 & 0.650000 & 0.100000 & 0 \end{pmatrix}, \\
\mathbf{P}^{10} &= \begin{pmatrix} 0.470354 & 0.362980 & 0.166667 & 0 \\ 0.362980 & 0.470354 & 0.166667 & 0 \\ 0.416667 & 0.416667 & 0.166667 & 0 \\ 0.383112 & 0.450221 & 0.166666 & 0 \end{pmatrix}, \\
\mathbf{P}^{100} &= \begin{pmatrix} 0.416667 & 0.416667 & 0.166667 & 0 \\ 0.416667 & 0.416667 & 0.166667 & 0 \\ 0.416667 & 0.416667 & 0.166667 & 0 \\ 0.416667 & 0.416667 & 0.166667 & 0 \end{pmatrix}.
\end{aligned}$$

Hay una convergencia aparente, pero para ningún valor de n tenemos todos los elementos de $\mathbf{P}^n$ positivos. Claro que esto tiene una explicación simple. El estado D (o 4) es transitorio y el subgrafo formado por los estados A, B y C forman una cadena de Markov en sí misma que, como puede observarse, tiene todos sus estados recurrentes y aperiódicos.

3.5.1. Cálculo de la distribución estacionaria

Hasta ahora hemos estado utilizando una calculadora o computadora para calcular potencias de la matriz de probabilidades de transición y así estimar distribución estacionaria. Sin embargo, existe una forma, a veces, más simple de hacerlo. Observemos que, en caso que exista la distribución estacionaria,

$$\vec{\pi} = \lim_{n\to\infty} \vec{p}(n) = \lim_{n\to\infty} \vec{p}(n-1)\mathbf{P} = \left[\lim_{n\to\infty} \vec{p}(n-1)\right] \mathbf{P} = \vec{\pi}\,\mathbf{P}. \tag{3.33}$$

Es decir que $\vec{\pi}$ es un autovector a izquierda de la matriz de probabilidades de transición $\mathbf{P}$.

Veamos cómo usar este hecho para calcular la distribución estacionaria en el caso del vendedor viajante:

$$\begin{aligned}
\big(a, b, c\big) &= \big(a, b, c\big) \begin{pmatrix} 0 & 1 & 0 \\ \frac{2}{3} & 0 & \frac{1}{3} \\ \frac{2}{3} & \frac{1}{3} & 0 \end{pmatrix} \Rightarrow \\
a &= \frac{2}{3}b + \frac{2}{3}c, && (3.34)\\
b &= a + \frac{1}{3}c, && (3.35)\\
c &= \frac{1}{3}b. && (3.36)
\end{aligned}$$

Si reemplazamos la Ec. (3.36) en las Ecs. (3.34)-(3.35),

$$\begin{aligned}
a &= \frac{2}{3}b + \frac{2}{3}\left(\frac{1}{3}b\right) = \frac{8}{9}b, && (3.37)\\
b &= a + \frac{1}{3}\left(\frac{1}{3}b\right) = a + \frac{1}{9}b \Rightarrow \frac{8}{9}b = a. && (3.38)
\end{aligned}$$

¡Obtuvimos la misma ecuación, pero tenemos 2 incógnitas! El hecho es que las ecuaciones originales no son linealmente independientes. Para poder resolver las tres incógnitas, necesitamos agregar una ecuación linealmente independiente. Dado que sabemos que la distribución de probabilidades suma 1, podemos escribir

$$\begin{aligned}
a &= \frac{2}{3}b + \frac{2}{3}c, && (3.39)\\
1 &= a + b + c, && (3.40)\\
c &= \frac{1}{3}b. && (3.41)
\end{aligned}$$

Reemplazando la Ec.(3.41) en las Ecs. (3.39)-(3.39),

$$\begin{aligned}
a &= \frac{2}{3}b + \frac{2}{3}\left(\frac{1}{3}b\right) = \frac{8}{9}b, && (3.42)\\
1 &= a + b + \left(\frac{1}{3}b\right) = a + \frac{4}{3}b \Rightarrow a = 1 - \frac{4}{3}b. && (3.43)
\end{aligned}$$

Igualando estas dos ecuaciones, tenemos

$$\frac{8}{9}b = 1 - \frac{4}{3}b \Rightarrow b = \frac{9}{20} \Rightarrow a = \frac{2}{5},\ c = \frac{3}{20}. \tag{3.44}$$

Es decir,

$$\vec{\pi} = \big(0.40,\ 0.45,\ 0.15\big)\,, \tag{3.45}$$

que coincide con los valores que habíamos estimado.

3.6. Cadenas de Markov absorbentes

Volvemos al modelo simple de vida que tiene sólo dos estados. ¿Podemos calcular el tiempo esperado de vida? Supongamos que comenzamos en el estado V y sea T_V el tiempo pasado en en dicho estado antes de la absorción. La probabilidad de vivir un año es

$$\mathrm{P}\big(T_V = 1 |\, X(0) = 2\big) = p, \tag{3.46}$$

donde hemos usado que el estado 2 es estar vivo. Del mismo modo,

$$\mathrm{P}\big(T_V = 2 |\, X(0) = 2\big) = pq, \tag{3.47}$$

$$\mathrm{P}\big(T_V = 3 |\, X(0) = 2\big) = pq^2, \tag{3.48}$$

$$\ddots = \ddots \tag{3.49}$$

$$\mathrm{P}\big(T_V = n |\, X(0) = 2\big) = pq^{n-1}, \tag{3.50}$$

donde por claridad hemos escrito $q = 1-p$. De esto se desprende que $T_V|X(0) = 2$ tiene distribución $\mathrm{Geo}(q)$ y

$$\begin{aligned} \mathrm{E}\left[T_V |\, X(0) = 2\right] &= \sum_{n=1}^{\infty} npq^{n-1} = p\sum_{n=1}^{\infty} \frac{d}{dq} q^n = p\frac{d}{dq}\sum_{n=0}^{\infty} q^n \\ &= p\frac{d}{dq}\frac{1}{1-q} = p\frac{1}{(1-q)^2} = (1-q)^{-1} \end{aligned} \tag{3.51}$$

Este resultado se puede generalizar como es explicado en el siguiente teorema que presentamos sin demostración. Primero necesitamos introducir la forma canónica de matrices de probabilidades de transición en cadenas de Markov con estados absorbentes. Recordemos la estructura de la matriz en el caso de la vida simple:

$$\mathbf{P} = \begin{pmatrix} 1 & 0 \\ p & q \end{pmatrix}.$$

En general, reordenando adecuadamente los estados, una cadena de Markov finita con n estados, r de ellos absorbentes, puede escribirse como

$$\mathbf{P} = \left(\begin{array}{c|c} \mathbf{I} & \mathbf{0} \\ \hline \mathbf{F} & \mathbf{Q} \end{array}\right), \tag{3.52}$$

donde $\mathbf{I}$ es la matriz identidad de $r \times r$, $\mathbf{0}$ es una matriz de ceros de dimensión $r \times (n-r)$, $\mathbf{F}$ es de $(n-r) \times r$ y $\mathbf{Q}$ es de $(n-r) \times (n-r)$.

Teorema 3.6.1 (**Tiempo hasta la absorción**). Sea una cadena de Markov absorbente finita con matriz de probabilidades de transición escrita en forma canónica como en la Ec. (3.52). Luego la matriz $\mathbf{I} - \mathbf{Q}$ tiene inversa, que llamamos *matriz fundamental* y escribimos como

$$\mathbf{M} = (\mathbf{I} - \mathbf{Q})^{-1}. \tag{3.53}$$

Los siguientes resultados relacionados con la matriz fundamental son importantes:

1. Sea $N(k)$ el número de veces que la cadena de Markov visita el estado k (antes de la absorción). Luego:

$$\mathrm{E}\left[N(r+j) |\, X(0) = r+i\right] = \mathbf{M}(i,j), \tag{3.54}$$

$$\mathrm{Var}\left[N(r+j) |\, X(0) = r+i\right] = \mathbf{M}_2(i,j), \tag{3.55}$$

con

$$\mathbf{M}_2 = \mathbf{M}\left[2\,\mathrm{diag}(\mathbf{M}) - \mathbf{I}\right] - \mathbf{M} \circ \mathbf{M}, \tag{3.56}$$

donde $\circ$ representa el producto de Hadamard (elemento a elemento) de dos matrices.

2. La probabilidad de ser absorbido por el estado j habiendo partido del estado $r+i$ viene dada por $\mathbf{G}(i,j)$ con

$$\mathbf{G} = \mathbf{M}\,\mathbf{F}. \tag{3.57}$$

Más formalmente,

$$\mathrm{P}\big(\exists n \ni X(k) = j \;\forall k \geq n |\, X(0) = r+i\big) = \mathbf{G}(i,j). \tag{3.58}$$

Vamos a aplicar este resultado al modelo complejo de vida. La matriz fundamental es

$$\mathbf{M} = \begin{pmatrix} 7.6923 & 61.5385 \\ 6.9231 & 65.3846 \end{pmatrix}. \tag{3.59}$$

Es decir que, comenzando del estado E, se espera pasar ~ 7.7 años en dicho estado y ~ 61.5 años sano, con una media de vida total de ~ 69.2 años. Del mismo modo, la probabilidad de terminar en el estado M comenzando en alguno de los otros dos estados, viene dado por

$$\mathbf{G} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}. \tag{3.60}$$

Este resultado es evidente ya que existe un solo estado absorbente, la muerte.

3.7. Referencias

Buena parte del material en este capítulo fue tomado de las presentaciones para las clases de Probabilidad y Estadística, dictada en el Instituto Tecnológico de Buenos Aires, preparadas por Francisco Villaverde. También nos hemos basado en el libro de Ross [4] y, en algunas cuestiones, en el clásico de Kemeny y Snell [3].

Bibliografía

[1] Dimitri Bertsekas and John N. Tsitsiklis. *Introduction to probability.* Athena Scientific, 2 edition, 2008.

[2] Terrence L Fine. *Probability and Probabilistic Reasoning for Electrical Engineering.* Prentice Hall, 2006.

[3] John G. Kemeny and J. Laurie Snell. *Finite Markov Chains*, volume 26. van Nostrand Princeton, NJ, 1969.

[4] Sheldon M. Ross. *Introduction to Probability Models.* Academic Press, 2014.