Estructura de Datos y Algoritmos

Jaime Nazar Anchorena

Contents

Unidad 1: Algoritmos **3**
- Tiempo de ejecucion . . . 3
  - Empiricamente . . . 3
  - Teoricamente . . . 3
  - Calculo del Big O . . . 3
- Espacio se RAM . . . 4
  - Empiricamente . . . 4
  - Teoricamente . . . 5
- Maven . . . 5
  - Goals . . . 6
  - Build Phases . . . 6
  - `pom.xml` . . . 6
  - Como correr el `.jar` fuera del entorno . . . 6
- Test-Driven Development . . . 7
  - Unit Testing . . . 7
  - Como testear en un Unit Test . . . 7
  - JUnit 5 . . . 7
  - Comparando resultados . . . 8
  - Ambiente de prueba . . . 9
  - JUnit Coverage . . . 9

Unidad 2: Algoritmos para textos **9**
- Definicion: Alfabeto . . . 10
- Definicion: String . . . 10
- Por que se lo denota λ? . . . 10
- Definicion: Conjunto de todos los string posibles . . . 10
- Definicion: Concatenacion de strings . . . 10
- Definicion: Prefijos, Sufijos y Subtrings . . . 10
- Definicion: Bordes . . . 10
- Dara Quality - Matching . . . 11
  - Minimas reglas que deberian aplicarse: . . . 11
  - Reglas especificas para un determinado tipo de datos . . . 11
- Algoritmos busqueda aproximada . . . 11

Soundex . . . 11
Metaphone . . . 13
Levenshtein Distance . . . 13
Optimizacion - Version compacta . . . 15
Q-Grams(o N-Grams) . . . 15
Algoritmos para busqueda exacta . . . 16
Fuerza bruta o Naive . . . 16
Knuth-Morris-Pratt . . . 17
Fulltext Retrieval . . . 18
Indices . . . 18
Definicion: Documento . . . 18
Definicion: Campo(Field) . . . 18
Definicion: Termino(Term) . . . 19
Almacenamiento . . . 19
Ranking de documentos . . . 20
Queries . . . 21
Analyzers . . . 22
Solr y Elasticsearch . . . 22
Indices y estructuras posibles . . . 22
Operaciones . . . 23
Teorema maestro . . . 23
Casos . . . 23
Expansion recursiva . . . 23

Estructuras lineales **24**

Unidad 1: Algoritmos

El analizis de algoritmos nos permite caracterizar la cantidad de recursos computacionales el usara un algoritmo dado, estas son:

1. Tiempo de ejecucion
2. Espacio que utilizan

En caso de considerar si un algoritmo es mejor que otro utilizando tanto la complejidad temporal como la espacial, pero generalmente ocurre que un algorimo es mejor espacialmente y peor temporalmente y viceversa. Hay que considerar cuales son los **tradeoff** y decidir en base a mi situacion.

> **Nota**: Una vez arman un algoritmo, no lo dejen asi, busquen maneras de mejorarlo.

Tiempo de ejecucion

Como los mido? Hay dos caracteristicas, ambas sirven, pero apuntan a cosas diferentes

1. Empiricamente
2. Teoricamente

Empiricamente

Debe ocurrir en la misma maquina, se puede haver con las clases `Timer` que hicimos en clase.

> **NOTA:** Cuidado, a veces un algorimo parece mejor que otro, pero en casos extremos puede ser peor o incluso fallar.

Teoricamente

Da una tendencia, no un tiempo dado. Categoriza los algoritmos, por ejemplo, todos los O(n^2). Consiste en una descripcion de alto nivel del algoritmo para evaluar su eficiencia, idependientemente del hardware y el software donde se ejecuto.

Para contar las operaciones y encontrar Big O, hay que contar las operaciones fijas y los ciclos. Hay que tener en cuenta el peor de los casos(siempre, por lo menos en esta materia) y encontrar la menor O grande. Si aparece una llamada a una funcion, hay que revisar la documentacion para verificar el numero de operaciones que requiere.

Calculo del Big O

La descripcion que buscamos para comparar algoritmos es una asintota(cota). Comportamiento asintotico superior o Big O se define como:

Sean T(N) y g(N) funciones con N > 0

Se dice que T(n) es O(g(N)) si Existe c > 0(no depende de N) y Existe n_c > 0 tal que Para Todo N >= n se cumple que 0 <= T(N) <= c * g(N). Ejemplo completo del campus:

Definición de Comportamiento asintótico superior u O grande (*asymptotic upper bound running time u O-notation*) de un algoritmo.

Sean T(N) y g(N) funciones con N >0.
Se dice que T(n) es O (g(N)) sii $\exists$ c > 0 (constante no dependiente de N) y $\exists$ n_0 > 0 tal que $\forall$ N $\geq$ n_0 se cumple que 0 $\leq$ T(N) $\leq$ c * g(N).

Ej: En nuestro caso, algoA tiene T(N) = 3 * N
Pero para hacer más complicada la discusión, supongamos que T(N) = 1 + 3 * N, o sea g(N) puede ser N.
O sea, si 0$\leq$ 1+3*N $\leq$ c * N ¿cuánto debe valer c?

0$\leq$ 1/N + 3 $\leq$ c
Si N es 2 entonces c >= 3.5
Si N es 5 entonces c >= 3.2, mejor la cota.
Si N es 500, c >= 3.002, mejor aún.
Yo quiero N$\rightarrow\infty$, entonces c >= 3. Así, el orden de algoA es O(N).

Encontré caracterizar una constante c, que es 3, para el cual ser verifica la fórmula para N$\rightarrow\infty$ ($\forall$ N $\geq$ n_0). El algoritmo es O(N).

Figure 1: Calculo formal del O grande

Basicamente, lo importante es encontrar el T(N) y de ahi se puede deducir O grande sin formalizar. Para calcular la complejidad temporal, no basta con analizar la cantidad de datos de entrada, la performance tambien puede depender de como vienen los datos.

Espacio se RAM

Similar al tiempo, existen metodos empiricos y teoricos para medir el espacio que un algoritmo ocupa en memoria, la complejidad espacial. Un programa presenta, datos, direcciones de retorno, alocaciones en memoria, etc.

Empiricamente

Para caracterizarlo en Java, hay que tener en cuenta el spacio que se aloca en:

- **Heap**: Cada vez que hacemos un `new` reservamos memoria en esta zona. Luego el GC libera esta zona cuando detecta que ya no esta siendo referenciada por alguna variable.
- **Stack**: Cada vez que se invoca un metodo se genera un **stack frame** para el mismo, conteniendo los parametros y variables temporales, asi como el lugar de la proxima instruccion a ejecutar(para que continue la ejecucion una vez termine la funcion).

Java permite configurar al heap con parametros, indicando la cantidad inicial de heap prelocada y la cantidad maxima posible de aloca. Al momento de necesitar mas recursos, se indica con los siguientes valors, dependen del equipo(cantidad de memoria, etc):

```
cd target
```

Correr el programa como:

```
java -Xms512m -Xmx4G -cp HeapOverflow-1.jar space.Generate
```

Para que el IDE lo haga automaticamente, agregar en VM args. En mi computadora:

Parametros	Heap Overflow en n
-Xms512m -Xmx4G	2043
-Xms512m -Xmx16G	9200+

Por otro lado, observando un programa recursivo en el stack:

Parametros	Stak Overflow en n
-Xss10k	Stack too small
-Xss1G	49 and I got bored

Teoricamente

Se miden en unidades, un puntero es una unidad, una variable es una unidad. No depende de la cantidad de variables su estas son siempre las mismas, si un algoritmo presenta una complejidad espaacial de 3 unidades, entonces es de orden O(1) (no seria el caso de un algorimo que usa recursividad).

Maven

Maven es un manejador de proyectos en Java, como objetivos propone:

- Proporcionar un sistema de construccion uniforme
- Proporcionar informacion de calidad del proyecto
- Proporcionar pautas para el desarrollo de mejores precticas.
- Permitir la migracion transparente a nuevas funcionalidades.

Como su funcionalidad principal, permite declarar **dependencias** para utilizar librerias externas o nuestras. Maven se encarga de compilar el proyecto, armar el `.jar` con lo que ya compile, y corre los test. Tambien, guarda los projectos localmente para poder utilizar dentro de otros proyectos.

Maven funciona de manera algoritmica, primero busca localmente la dependencia en nuestro repositorio local. Caso contrario, lo busca en internet, si lo encuentra, lo descarga.

Goals

Tareas especificas dentro del build, por ejemplo:

- `mvn jar.jar`: Arma un `/jar` desde codigo ya compilado
- `mvn dependency:tree`: Muestra las dependencias
- `mvn exec java`: Corre el proyecto, `exec` es el plugin y `java` es el goal.

Build Phases

Etapas del armado del proyecto, por ejemplo: - `mvn compile` - `mvn test`

`pom.xml`

Aca declaro como sera my libreria, como aparecera para los demas en el repositorio. Ademas, se le pueden agregar dependencias que tu codigo utilize.

```
<groupId>ar.edu.itba.eda</groupId>
<artifactId>TimerJoda</artifactId>
<version>2</version>
```

Donde `ar.edu.itba.eda` no es el nombre del paquete donde se encuentra el codigo, sino que es el directorio donde se guarda la libreria en el repositorio.

Como correr el `.jar` fuera del entorno

Fuera del entorno de desarrollo, tenemos que poder correr nuestro programa(como el cliente). Para poder compilar todo el entorno en el archivo, hay que agregar un plugin en el `pom.xml`. Lo que va a hacer es juntar todas las dependencias en un unico `.jar`, es basicamente instrucciones extra. Logicamente, el ejecutable generado ocupara mucho mas espacio.

Se puede ejecutar especificando donde esta la clase main.

```
java -cp ***.jar core.AnalisysTimer
```

Pero tambien es posible simplemente decirle que es un ejecutable, pero para que sepa donde esta el main hay que ponerlo en el manifest(independiente de maven), sino da error. Ademas, maven tiene la opcion de agregar en la seccion de plugin para que haga eso automaticamente.

```
<configuration>

    ...

    <archive>
        <manifest>
            <mainClass>core.AnalisysTimer</mainClass>
        </manifest>
    </archive>
```

```
    ...

</configuration>
```

Donde core es el package y AnalisysTimer es la clase. Luego, puedo correr my programa con:

```
java -jar ***.jar
```

Test-Driven Development

- TDD es una metodologia que comienza por los test y luego pasa a la implementacion.
- Permite enfocarse en la definicion de la interfaz y del comportabmiento y no en los detalles de implementacion.
- Ve al sistema que se va a desarrollar como una caja negra que todavia no existe.
- Apunta a que todas las funcionalidades tengan algun test.

Unit Testing

Para testear pertes individuales del programa.

- Automatico
- Verifican un unico caso por test
- Repetible
- Independientes de otros test o de condiciones externas.

Como testear en un Unit Test

- Caso de metodo o funcion:
  - Casos tipicos
  - Casos de borde
  - Casos de error
  - Casos de excepcion
- Caso de una clase:
  - Secuencias de llamadas validas
  - Secuencias de llamadas invalidas
  - Chequeo de invariantes

JUnit 5

Framework de java para realizar pruebas de desarrollo de una aplicacion, ha muchos, pero vamos a usar este. Puede comparar resultados de las invocaciones de metodos, o verificar si una excepcion fue lanzada o no. Ademas, un caso de prueba es abortado ni bien falla alguna verificacion.

Para que funcione con maven y poder hacer `mvn test`, hay que agregar un plugin:

```
<plugin>
    <groupId>org.apache.maven.plugins</groupId>
    <artifactId>maven-surefire-plugin</artifactId>
    <version>3.5.2</version>
</plugin>
```

Y en dependencias:

```
<dependency>
    <groupId>org.junit.jupiter</groupId>
    <artifactId>junit-jupiter-engine</artifactId>
    <version>5.12.0</version>
    <scope>test</scope>
</dependency>
```

Comparando resultados

El test unitario mas simple consiste en comparar el resultado obtenido con el resultado esperado, para ello se puedde utilizar metodos estaticos como `asserEquals(valorEsperado, valor Obtenido)` o `assertTrue()`.

Ademas, si un metodo lanza una excepcion, el mismo se considera que fallo. Si se espera que lanze una excepcion, si indica como `assertThrows(RuntimeException.class, () -> ...)`. Tambien puede teatear y comparar valores de punto flotante, basicamente tiene funciones para casi todos los casos de pruebas.

Para Maven, en las clases con los test, hay que agregar la palabra clave `Test` en el nombre de la clase, de esa manera Maven va a carrer automaticamente los test en el deployment. Tambien, es obligatorio agregar un `@test`.

```
class TimerTest {

    @test
    @DisplayName("Probar el timer") <- opcional
    void getDurationExceptionTest() {
        ....

        assert...();
    }
}
```

> **NOTA:** Testear Strings es muy dificil(no recomendado), fallan por la mas minima diferencia.

Ambiente de prueba

Frecuentemente se desea tener un ambiente de prueba perfijado(no tener que declarar la misma variable todo el tiempo), para eso se usan anotaciones especiales:

- `@BeforeAll` - Se ejecuta entes de todos los casos de prueba
- `@BeforeEach` - Se ejecuta antes de cada `@Test`
- `@AfterEach`
- `@AfterAll`
- y mas.

Ejemplo:

```
@BeforeAll
static void initAll() {
    ...
}

@AfterEach
void tearDown() {
    ...
}
```

Teniendo en cuenta `MyTimer`, podriamos hacer:

```
private MyTimer timer;

@BeforeEach
void instanceTimer() {
    this.timer = new MyTimer();
}
```

JUnit Coverage

Como verifico que el testeo recorra todo el codigo?

JUnit contempla eso, si quiero ver la covertura de mis test, JUnit generara un reporte.

Unidad 2: Algoritmos para textos

La pricipal motivacion de estos algoritmos es analizar y comparar textos, ya sea para detectar copias o para detectar similitudes. Esto se aplica en areas como en la politica y la biologia. Otra razon mas simple, es para buscar typos y corregirlos. La matematica es muy util para formalizar todo esto.

Definicion: Alfabeto

Se denota Σ y es el conjunto de simbolos o caracteres.

Definicion: String

Dado un alfabeto Σ y $k_{\geq 0} \in N$, un string `S` es un elemento de Σ^k

La longitud del stt=ring es k y si $k = 0$ entonces se lo denota λ.

Por que se lo denota λ?

Oara evitar los problemas que tienen los compiladores, un meta-simbolo no deberia ser al mimso tiempo parte del alfabeta. Los lenguages de programacion violan estas relgas y ahi surgen los problemas.

Para evitar ambiguedades obliga a escapar al simbolo comillas dobles cuando participa del string, es decir, `"hola"que"` para el compilador es simplemente 'hola', pero `"hola\"que"` es 'hola"que'. Sin embargo, esto no soluciona la ambiguedad pues '\' es parte del alfabeto. Si no nos presenta confucion, podemos hablar de `""` como el string vacio.

Definicion: Conjunto de todos los string posibles

Dado un alfabeto Σ, $\Sigma^{@} = \cup\Sigma^k$ con $k_{\geq 0} \in N$

> **Nota**: Deberia ser sigma^asterisco, lo reemplace con @

Definicion: Concatenacion de strings

Dado un alfabeto Σ, y $u, w \in \Sigma^{@}$

Se llama **concatenacion** al string definido como uw (uno a continuacion del otro).

Definicion: Prefijos, Sufijos y Subtrings

Dado un alfabeto Σ y los strings $x, w, z \in \Sigma^{@}$. Sea $p = xyz$. Se dice que x es un **prefijo** de p. Se dice que w es un **substring** de p. Se dice que x es un **sufijo** de p.

> λ representa vacio, entonces es sufijo, prefijo y borde.

Definicion: Bordes

Dado un alfabeto Σ y los string $x, y, z \in \Sigma^{@}$. Si $p = wz = zw$ donde $|x| = |z|$, se dice que w es un **borde** de p.

> Un borde es prefijo y sufijo al mismo tiempo.

Dara Quality - Matching

Busqueda aproximada, los buscadores pueden usar varias tecnicas para esto y suelen ser muy variadas. Algunas de ellas(las estrategias pueden ser combinaciones de uno o mas de estas), de menos a mas avanzadas:

- Busca palabras y si las palabras no estan en el corpus de los documentos indizados, encontrar las que mayor similitud posean y sugerirlas.
- Tomar el idioma que tiene configurado el browser para saber en que corpus buscar las palabras usadas. Hay reglas conocidas por el idioma en cuestion, lo cual permite su deteccion.
- Sabiendo que los usuarios buscan palabras y cuando fue un error de tipeo, no clickean nada del resultado e intentan realizar inmediatamente la busqueda arreglada, almacenan estas buscasdas erroneas para su uso posterior en caso de que otro usualrio haga algo similar.

Minimas reglas que deberian aplicarse:

1. Sacar blancos de comienzo y final(trim) - Pero no es suficiente, podria haber blancos entre medio
2. Buscar pasando todo a mayuscula o minuscula
3. Si se conocen abreviaturas, usarlas - BA por Buenos Aires
4. Los simbolos de punctuacion, eliminarlos
5. Si se conocen sinonimos, usarlos

Reglas especificas para un determinado tipo de datos

Este tipo de cosas se tienen que tener en cuenta:

- Fechas y sus formatos
- La hora y sus formatos
- Numeros
- Numeros decimales
- Strings correspondientes a nombres y apellidos (depende del orden)

Algoritmos busqueda aproximada

Soundex

Es un algoritmo fonetico, es decir, codifica una palabra segun como suena. Intenta solucionar problemas de pronunciacion, fue creado para el alfabeta ingles, pero existen implementacinoes para otros idiomas. Primer algorimo fonetico inventado, de la decada de 1930 y fue utilizado hasta la decada de 1990.

Idea, aquellas palabras que suenen igual, aunque no se escriban igual, deben ser codificadas de la misma manera. Lo que hicieron fue agrupar letras que sonaban parecido.

Soundex siempre devuelve un `OUT` de exactamente 4 caracteres formados por:

26 Letras	Pesos fonéticos
A, E, I, O, U, Y, W, H	0 -- no se codifica
B, F, P, V	1
C, G, J, K, Q, S, X, Z	2
D, T	3
L	4
M, N	5
R	6

Figure 2: Categorizacion de letras del algorimo Soundex

`[Letra][Digito][Digito][Digito]`

Pasos

1. Pasar todo a mayuscula y dejar solo las letras(digitos, simbolos de punctuacion, espacio, etc., se eliminan)
2. Colocar `OUT[0] = IN[0]` - La primera se la quedan pues es la mas importante
3. Se calcula la variable `last` como el peso fonetico de `IN[0]` 3,1 Calcular variable `current` con un peso fonetico de `iter`. Si es diferente a 0 y no concide con `last`. 3.2 `last = current`
4. Para cada letra en `IN`, iterar hasta completar 3 digitos o terminar de procesar `IN`.

Un caso, si un producto no se encuentra en la categoria esperada

Como usarlo Soundex no es una metrica, hay que definir como obtener una metrica a partir de Soundex.

Definicion de similitud Comparo caracter a caracter y cuento cuantas veces coicidieron. Si ninguno concide, entonces da 0. Si coinciden 3 caracteres, entonces da 0.75, es decir, la metrica va de 0 a 1.

> **Nota**: Un Hashmap es la mejor opcion para hacer un lookup, pero para que sea O(1) tiene que cumplir con ondiciones especiales. Para el caso de Soundex, un hashmap encubierto.

Metaphone

Aparece en 1990 y presenta mejoras en relacion a Soundex, no hace la clasificacion, sino que la salida son letras que representan los osnidos. Genera un encoding de longitud arbitraria. En wikipedia esta bien documentado el algoritmo, pero recomiendad usar la version en ingles pues es la que esta mejor explicada.

> Se recomienda ver la implementacion en `apache/commons-codec` una vez implementaste tu version, ahi hay muchos algoritmos conocidos.

Definicion de similitud La similitud entre 2 textos puede pensarse como la proporcion de caracteres coincidentes entre los encodings respecto de la misma longitud, pero cuando no tienen la misma longitud, no es trivial. Para ello se utiliza **Levenshtein Distance**.

Levenshtein Distance

No es un encoding, calcula la **minima** cantidad de operaciones necesarias para transformar un string en otro. Las operaciones validas son:

- Insertar
- Borrar
- Sustituir un caracter

> **Nota**: Esto es la version canonina, hay alternativas con mas operaciones.

Aquellos strings iguales deben tener distancia 0. Basicamente hay muchas maneras de ir a un string a otro, como podemos obtener la manera con la menor cantidad de pasos?

La forma manual de hacerla es con una matriz, arriba va una palabra y al costado otra, cada palabra debe comenzar con un meta-caracter pues debe ser un simbolo que no esa en el lenguaje.

	meta-c	B	I	G		D	A	T	A
meta-c	0	1	2	3	4	5	6	7	8
B	1								
I	2				x				
G	3								
D	4								
A	5								

	meta-c	B	I	G		D	A	T	A
T	6								
A	7								

Para calcular el valor de x, esa celda representa `L('BIG', 'BI')`. Pero hay varias posibilidades para decidir el valor de x en base a los anteriores, el objetivo es obtener el menor. Los tres valores candidatos:

1. `L('BI', 'B')`(Celda anterior, diagonalmente) + `G == I?0:1`
2. `L('BIG',' B')`(Celda anterior, verticalmente) + 1
3. `L('BI',' BI')`(Celda anterior, horizontalmente) + 1

La ultima celda sera el resultado.

Ejempo casi-resuelto:

	meta-c	B	I	G		D	A	T	A
meta-c	0	1	2	3	4	5	6	7	8
B	1	0	1	2	3	4	5	6	7
I	2	1	0	1	2	3	4	5	6
G	3	2	1	0	1	2	3	4	5
D	4	3	2	1	1	1	2	3	4
A	5	4	3	2	2	2	1	2	3
T	6	5	4	3	3	3	2	1	2
A	7	6	5	4	4	4	3	2	**1**

> Este algoritmo es caracteristico, pues el minimo tomado en algun lugar intermedio llega al minimo global. Minimo local coincide con minimo global(no siempre ocurre).

Normalizacion La distancia es un numero cualquiero, si quiero un numero entre 0 y 1, se obtiene de:

$$LevenshteinNormalize(str1, str2) = 1 - \frac{Levenshtein(str1, str2)}{\max(str1.len, str2.len)}$$

Propiedades matematicas El algoritmo cumple con las siguientes propiedades.

- **Simetria**: $L(s1, s2) = L(s2, s1)$
- **Desigualdad**: $L(s1, s2) + L(s2, s3) >= L(s1, s3)$

Programacion dinamica Es una tecnica que consiste en rausar valores previamente calculados para no tener que recalcularlos repetidamente. Sirve, si para cierto calcula, pueden reusarce valores previos y tiene la desventaja de que estoy cambiando tiempo por espacio(`cache`).

Para buscar estos valores necesitamos una estructura de datos que permita buscar valores lo mas rapido posible -> matriz, vector, etc.

De esta manera, por ejemplo, el algoritmo `fibonacci` pasa de ser $O(2^N)$ a $O(N)$.

Variantes Otras variantes no consideran que las operaciones valos todas igual. Algunas es mas cara que otra y cambia la formula de distancia. Algunas agregan operaciones.

Ejemplo: Se agrega la operacion transposicion. Contempla el tipico error de escritura en el cual se invierten las letras.

Complejidad temporal Notar que a pesar de ser dos `if` anidados, la complejidad no sera $O(N^2)$ pues la matriz no sera cuadrada, tendra una complejidad de $O(N \cdot M)$.

Complejidad espacial Similar a la temporal ya que mantenemos la matriz, sera un orden de $O(N \cdot M)$

Optimizacion - Version compacta

Mas util si solo necesito conocer la similitud. Notar que no necesitamos todas las filas anteriores para seguir con la siguiente fila, entonces se propone un cambio de punteros, basicamente utilizando solo dos filas en vez de la matriz.

Solo hay que hacer un cambio de variables, no conviene copiar todo un arreglo. Notar, que tendra otra complejidad espacial. De todas formas, los dos algoritmos sirven, para distintas cosas. El menos compacto sirve para obtener los pasos que tendria que hacer para transformar los strings(haciendo el camino inverso).

Q-Grams(o N-Grams)

Consiste en generar los pedazos que componen un string. La distancia entre 2 strings estara dada por la cantidad de componentes que tengan en comun. No es un econding sino que simplementte realiza la comparacion.

Si Q es 1 se generan componentes de longitud 1. Si Q es 2 se generan **bigramas**, si Q es 3 se generan **tri-gramas**. Nosotros vamos a completar con $Q - 1$ al comienzo y al final para que todas aparezcan la misma contidad de veces.

Por ejemplo: `Q-grams(JOHN) = {J, O, H, N, #J, JO, OH, HN, N#, ##J, #JO, JOH, OHN, HN#, N##}`

String matching Para comparar dos strings, se compararn los arreglos de dos palabras y se cuenta cuantos elementos tienen en comun. Luego, la distancia sera la cantidad de elementos en comun. La implementacion que es mas usada, es tri-grama y esa es la que vamos a usar nosottros. Si al comparar aparece el mismo patron dos veces en uno y una vez en el otro, solo se cuenta una vez, es decir, la comparacion es 1 en 1.

Normalizacion

$$Q{-}grams(str1, str2) = \frac{\#TG(str1) + \#TG(str2) - \#TGNoShared(str1, str2)}{\#TG(st1) + \#TG(str2)}$$

> **Nota**: En general, nuca se usa un algoritmo individual, sino que se usa una combinacion de varios. Utilizando una formula que los combine.

Algoritmos para busqueda exacta

Fuerza bruta o Naive

```java
public static int indexOf(String str, String pattern) {

    char[] s = str.toCharArray();
    char[] p = pattern.toCharArray();

    int j = 0;

    for (int i = 0; i < s.length; i++) {
        if (s[i] == p[j]) {
            j++;
        } else {
            i -= j;
            j = 0;  // Puede estar mal, pues tengo que ir para atras de nuevo
        }

        if (j == p.length) {
            return i - j + 1;
        }
    }
    return -1;
}
```

Voy comparando char a char y verificando si coinciden, recorriendo todo el array. El peor caso es que el query no encuentre el target.

- **Complejidad temporal** = O(n*m), donde `n = target.length` y `m = query.length`
- **Complejidad espacial**: O(1)

Este algoritmo no es el mejor ya que no aprovecha lo que aprendio en el recorrido.

Knuth-Morris-Pratt

Examina el **target** de izquierda a derehca, pero usa conocimiento sobre los caracteres comparados antes de determinar la proxima posicion del patron a usar. Preprocesa el query antes de la busqueda una vez, con el objetivo de analizar la estructura(las caracteristicas del patrton query). Para ello contruye una tabla **Next** del mismo `length` que el query. No vuelve para atras, eso es muy importante ya que reduce la complejidad temporal. La tabla tiene en cada posicion `i` la longitud del **borde propio** mas grande para el substring desde 0 hasta `i`.

Implementacion de la computacion de Next:

```
private static int[] nextComputation1(char[] query) {
    int[] next = new int[query.length];

    int border=0;  // Length of the current border

    int rec=1;
    while(rec < query.length){
        if(query[rec]!=query[border]){
           if(border!=0)
                border=next[border-1];
           else
                next[rec++]=0;
       }
       else{
            border++;
            next[rec]=border;
            rec++;
        }
    }
    return next;
}
```

Es muy astuta la implementacion y tiene complejidad temporal O(n).

Para calcular el `search` sin el **backtracking**, avanza entre la tabla del `query` y el `target`, cuando no haya coincidencias se **shifttea** el `query` de la siguiente manera:

...(Falta completar)

Finalmente, la complejidad temporal sera O(n+m)

Fulltext Retrieval

El problema es que KMP realiza la busqueda en un documento, pero si quisiera buscar sobre un grupo de documentos, nos conviene generar un indice de dicha coleccion para luego buscar a traves del indice. Lo que ocurre es que generalmente la **query** no siempre es la misma, pero los documentos no cambian, entonces conviene preprocesar los documentos(similar a lo que hace google). Esto se conoce como contruir el **corpus**. Eso es lo que hacen las bibliotecas de **Fulltext Retrieval**. Existe una biblioteca de codigo abierto para esto: **Lucene**. Tomamos ventaja de los indices obtenigos.

Basicamente, esta biblioteca nos permmite armar nuestro propio "search engine", tiene hasta el manejo de sinonimos.

Indices

Un indice es una estrucutra que permite llegar rapidamente al dato buscado, pero si se modifica un documento en la coleccion debe actualizarse. Es decir, su ventaja esta en la busqueda y tiene la desventaja de nececsitar actualizar la estructura cada vez que se modifique un documento.

Lucene usa un **archivo invertido** (conjnuto de terminos que dicen a que documentos pertenecen). Es un mapping:

Termino -> Documento

Por ejemplo:

```
MapReduce -> {Doc1, Doc2}
Grid -> {Doc2}
...
```

De esa manera evita tener que ir a mirar los documentos.

Definicion: Documento

Un documento en Lucene es una secuencia de **campos**(fields). Cuando se ingresa un documento en Lucene, automaticamente se asociara un ID(docid).

Definicion: Campo(Field)

Un campo en Lucene es un par nombre y secuencia de 1 o mas terminos.

```
// Como crearlo
FieldType aField = new FieldType();

// Como decidir se se almacena o indexa
aField.setStored(true);

// Como especificar como indexar(depende cuanto espacio queres que ocupe)
```

```
aField.setIndexOptions(IndexOptions.NONE);
// - NONE(no se indexa)
// - DOCS(se indiza solo con los doc ids en los que esta)
// - DOCS_AND_FREQS(similar a DOCS, y ademas se especifica la frecuencia)
// - DOCS_AND_FREQ_AND_POSITIONS(Idem a anterior, ademas de las posiciones ordinales)
// - DOCS_AND_FREQS_AND_POSITIONS_AND_OFFSETS(No lo vamos a usar, solo para frontend)
```

Para evitar escribir `DOCS_AND_FREQ_AND_POSITIONS` todo el tiempo, se usa `TextField`, el cual es simplemente un alias. La opcion de almacenar solo se podra hacer si no viene de un **stream**, sino lo estaria almacenando 3 veces: en el stream(file system), en el indice y ademas otra vez literal fuera del archivo.

Definicion: Termino(Term)

Un termino Lucene es una secuencia de bytes(Podrian interpretarse como Strings, numeros, etc. asociada a cierto campo. Dos secuencias de bytes con igual contenido pero asociadas a 2 campor diferentes se consideran diferentes.

> **Nota**: Nosotros solo vamos a usar Strings como terminos.

Almacenamiento

Lucene es peculiar ya que tiene una zona donde guarda informacion que no es el archivo invertido. Al crear un campo(nombre y terminos) y asociarlo a cirto documento puedo optar por:

- Almacenarlo en Lucene pero fuera del archivo invertido. Eso significa que se lo almacena literal(sin procesamiento, no se lo separa en tokans, no se pasa a minuscula, etc.). Es decir, esta en Lucene pero no esta indexado, entonces no participa de las busquedas.
- Indexarlo en el archivo invertido Lucene. Eso significa que esta tokenizado o no(segun lo configure) forma parte del archivo invertido y sus terminos(to kens), entonces participan de las busquedas.

  > **Nota**: Uno busca palabras especificas, no busca signos de punctuacion, preposiciones, etc. Solo nos interesan las palabras clave.

Un field puede ser solo almacenable, solo indexable o ambas cosas. Es obligatoria que sea, por lo menos, una de ellas. La informacion se almacena de distintas maneras dependiendo de la opcion que eleji para los fields. Es una tabla ordenada alfabeticamente por token.

Value term	Freq en docs	[docid:freqs in docif:[position]]
...	...	...

Como se le asigna el id al doc? Si quiero el nombre y no el id? Para eso sirve el almacenamiento fuera del index, el nombre del path lo puedo almacenar en

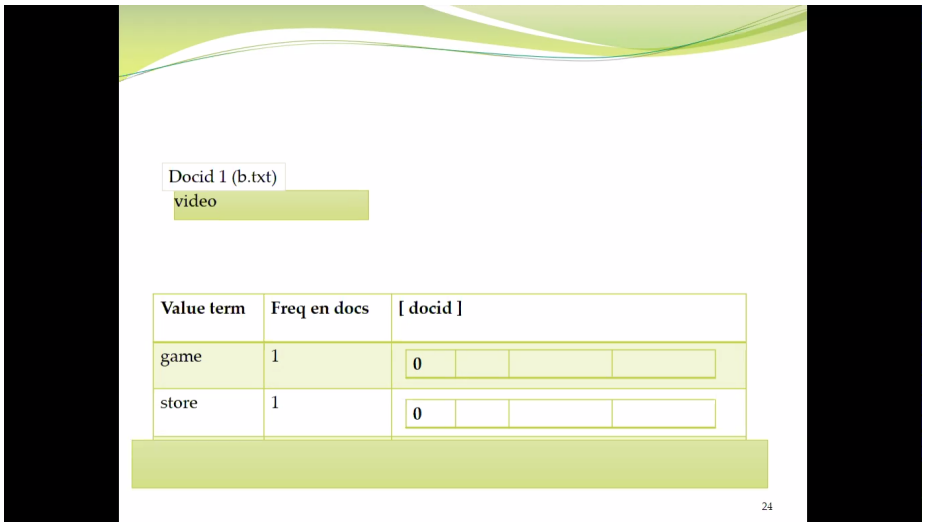

Figure 3: Ejemplo almacenamiento Lacene

el almacenamiento aparte. Es un exelente uso para el almacenamiento fuera del indice en Lucene.

Ranking de documentos

Si busco un **query** y trae varios documentos, cual documento aparece primero? cual es mas relevante que otro? Esto se decide a partir de una formula.

$$\text{Score}(DOC_i, query) = \text{FormulaLocal}(DOC_i, query) \cdot \text{FormulaGlobal}(DOC, query)$$

Formula local: Quiere calcular que tan relevante es esa query respecto a un documento en particular a rankear. Por lo tanto, si busco un paper en Java, me va a importar mas el que mencione mas dicho lenguaje. Si dos documentos tienen la misma cantidad de apariciones, se elije el de mayor volumen.

$$\text{FormulaLocal}(DOC_i, query) = \sqrt{\frac{\#\text{frec term en } DOC_i}{\#\text{term existentes en } DOC_i}}$$

Formula global: Quiere calcular que tan relevante es esa query respecto a la coleccion de documentos existente. Tampoco se quiere linealidad, sino que tiene escala logaritmica.

$$\text{FormulaGlobal}(DOC, query) = 1 + \log_e\left(\frac{1 + \#\text{docs en la coleccion}}{1 + \#\text{docs que contienen la query}}\right)$$

Multi-Query Si es una query multi termino, el score queda:

AND

$$\text{Score}(DOC_i, query) = \Sigma_{\text{term in query, without NOT}}\text{FormulaLocal}(DOC_i, term) \cdot \text{FormulaGlobal}(DOC, term)$$

OR

$$\text{Score}(DOC_i, query) = \Sigma_{\text{term in query, without NOT}}\text{FormulaLocal}(DOC_i, term) + \text{FormulaGlobal}(DOC, term)$$

Queries

Vamos a usar dos aplicaciones: IndexBuilder y TheSearcher(se encarga de aceptar consultas, utiliza el indice, solo devuelve los ids). **SOLO** usar las versiones de las teoricas, sino no nos va a funcionar porque cambio la API.

Hay dos maneras para hacer **queries**(Una mas alto nivel que otra):

- **API**
  - `TermQuery`
  - `PrefixQuery`
  - `PhraseQuery`
  - `WildcardQuery`
  - `FuzzyQuery` <- Usa Damerau-Levenstein(Con transposicion) con un MaxEdit=2
  - `BooleanQuery`
  - etc
- **Lenguaje lado cliente**
  - `TermQuery`: Con `content:game`.
  - `PrefixQuery`: Con `content:ga*`.
  - `TermRangeQuery`: Con `content:{gaming TO gum]`, donde `{` es abierto y `]` cerrado.
  - `PraseQuery`: Con `content:\"store game\"`, busca frase donde la primer palabra sea 'store' y la segundo 'game'.
  - `WildcardQuery`: Con `content:g??e`.
  - `FuzzyQuery`: Con `content:gno~2`, no se toman mas de 2, estaria muy lejos.
  - etc.

El `QueryParser` es una extension que permite simplificar los query. Ejemplo de uso:

```
String queryStr= "content:game";

QueryParser queryparser = new QueryParser(null, new StandardAnalyzer() );
Query query= queryparser.parse(queryStr);
```

Si busco 'ga' con `content:ga` no va a encontrar 'game', pero si quiero buscar el analogo a `PrefixQuery` busco prefijo `ga` con `content:ga*`. Si ya se que las

queries siempre van a ser en `content`, se podria pasar como default y no tener que poner el prefijo.

```
String queryStr= "game";

QueryParser queryparser = new QueryParser("content", new StandardAnalyzer() );
Query query= queryparser.parse(queryStr);
```

> **Nota**: Si pones `content:store content:game` lo va a tomar como `content:store OR content:game`, hay que tener cuidado. Tambien acepta `||` como **or**.

Analyzers

Si buscamos 'Game' no lo va a encontrar, esto lo solucionamos con un analyzer, el cual se va a encargar de pasar a minuscula, sacar numeros, etc. Permite separar los tokens, en el ejemplo anterior usamos el `StandardAnalyzer`, pero hay muchos mas, permitionme filtrar con precision lo que quiero que se indexe y lo que no. Si ninguno te sirve, podes usar un `CustomAnalyzer` y personalizarlo como quieras.

```
Analyzer a = CustomAnalyzer.builder()
            .withTokenizer("standard")
            .addTokenFilter("lowercase")
            .addTokenFilter("stop")
            .addTokenFilter("porterstem") // Word family
            .addTokenFilter("capitalization")
            .build();
```

El `SpanishAnalyzer` busca la raiz de la palabra ya que podria ser similar al del castellano(Stemmer Algorithm).

Solr y Elasticsearch

Lucene no ofrece escabilidad, para ello se utiliza Solr o Elasticsearch. Para realizar bsuquedas de gran escala, se ditribuye la busqueda en varias computadoras. Una compuradora dirije y pide la busqueda y el resto realiza la busqueda en diferentes documentos.

Indices y estructuras posibles

En la seccion anterior se utiliza un indice como estructura auxiliar para guardar los terminos. Es muy importante poder realizar busquedas de la manera mas eficiente posible. Se utiliza una clave de busqueda que permite encontrar rapidamente al resto de la informacion(como un mapa). Por ejemplo, puedo buscar la informacion de un aluno por legajo, por edad, etc. Para el caso de la edad, el indice esta **descompactado** ya que aparece el 20 mas de una vez. Si el indice

esta **compactado**, aparece una edad una unica vez con una lista asociada de los alumnos con dicha edad.

Operaciones

Ahora bien, el indice no solo se utiliza para buscar, sino que tambien hay operaciones:

- Busqueda
- Insercion
- Borrado

La complejidad temporal de cada una depende del tipo de estructura, por ejemplo, si se trata de un arregla con espacio prealocado, si quiero insertar es simplemente cuestion de insertar al final, pero todo cambia si tiene que ser ordenado o tengo que aumentar el espacio.

No hay estruturas de datos perfectas, dependen del caso. Nosotros vamos a utilizar un arreglo ordenado,

Teorema maestro

Permite calcular la complejidad temporal de un algoritmo recursivo, solo sirve para recurrencias simetricas. Si formulando la cantidad de operaciones de un algoritmo recursiva me queda como:

$$T(N) = a \cdot T(\frac{N}{b}) + c \cdot N^d$$

Entonces estamos en condiciones de utilizar el teorema maestro.

Donde:

- N es el tamano de entrada del problema
- $a \in N_{\geq 1}$ es la cantidad de invocaciones recursivas realiza ese paso
- $b \in N_{>1}$ es la tasa en la que se reduce el tamano del input
- ...

Casos

- Si $a < b^d$ entonces el algoritmo es $O(N^d)$
- Si $a = b^d$ entonces el algoritmo es $O(N^d \cdot \log(N^d))$
- ...

  Nota: No siempre se puede aplicar el teorema, como el caso de Fibonacci

Expansion recursiva

Otra manera de encontrar la complejidad de los algoritmos recursivas, lo importante es encontrar Times(N), si esta mal despues todo va a estar mal.

Estructuras lineales